

论文编号:

广州商学院

本科毕业论文（设计）

题目： 基于 DETR 的交通标志与车辆多目标检测系统的设计与实现

姓名： 郭嘉俊

学号： 202206050011

学院： 信息技术与工程学院

专业班级： 软工 2203

指导教师： 赵菊芳

2026 年 6 月

本科毕业论文（设计）原创性声明

本人郑重声明：所呈交的毕业论文（设计），是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品或成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

作者签名：郭嘉俊

日期：2026 年 6 月 1 日

本科毕业论文（设计）版权使用授权书

本论文（设计）作者完全了解学校有关保留、使用毕业论文（设计）的规定，同意学校保留并向国家有关部门或机构送交论文（设计）的复印件和电子版，允许论文（设计）被查阅和借阅。本人授权广州商学院可以将本论文（设计）的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本论文（设计）。

本论文（设计）属于

1. 保密□，在_____年解密后适用本授权书。
2. 不保密☒。

（请在以上相应方框内打“√”）

作者签名：郭嘉俊

日期：2026 年 6 月 1 日

指导老师签名：赵菊芳

日期：2026 年 6 月 1 日

摘要

本文以车载前单目摄像头，即驾乘者的第一视角来执行道路视频分析任务，按照此方向展开设计并创建一套依托 DETR 的交通标志及车辆多目标检测系统。该系统利用 Deformable DETR 并结合轻量化在线追踪算法计算得出相对稳定的轨迹，再凭 Streamlit 达成前后端融合的叠加可视化效果，更直观地显现检测结果和追踪结果。论文着重针对集合预测、可变形注意力、小目标检测以及评价体系执行系统的整理工作，从而确立起对于交通标志“小尺度、长尾”特性和车辆“聚集、遮挡”情况的建模标准和衡量指标。

项目在系统设计上执行了需求分析和总体设计，形成“解码→检测→联合→渲染→交互→导出”这样自末端到末端的流程，并创建起同 COCO 标注规范相符合的数据接口，在执行方面着重于模型推断效率以及系统运作这两个方面。

对系统性能进行改良之后，经由 FPS、端到端时延以及显存占用这些指标来剖析改良的效果。最后针对 BDD100K、TT100K 及自行采集的视频来做检测失效案例分析。结果表明，系统在即时性和小目标检测之间取得了比较恰当的协调，系统的总体表现符合预期。同时文章也显示，极端小目标和长尾类别依旧是主要的难点，可以采用蒸馏、高效 Transformer 等更为精确的数据加强方法来持续推进改良工作。

关键词：Deformable DETR；交通标志检测；车辆多目标检测；小目标检测

ABSTRACT

The research focuses on front-facing monocular cameras as the main viewpoint for driver-centric road video analysis, and it designs and implements a multi-object detection system for traffic signs and vehicles using the DETR framework. The system at its heart uses Deformable DETR, combined with a light online tracker that gives strong spatiotemporal paths. In order to connect raw inference with a natural understanding, we used Streamlit to create an integrated frontend-backend visualization pipeline where detection and tracking results were overlaid in real time.

Apart from building systems, this study offers a comprehensive integration of set prediction, deformable attention, and small object detection methods, with a focus on improving the modeling techniques and evaluation criteria suited for the “small-scale, long-tail” characteristic of traffic signs and the "density and occlusion" issues faced during vehicle detection.

In the engineering phase, the design moves from strict requirement analysis to an entire end-to-end pipeline that includes “decoding, detection, association, rendering, interaction, and exportation,” along with a data interface that conforms precisely to the COCO annotation standard. In terms of implementation, it focuses on improving the efficiency of inference and the stability of the system, and its effectiveness is verified by indicators such as FPS, end-to-end latency, and VRAM usage.

Lastly, after conducting thorough evaluations on BDD100K, TT100K, and proprietary datasets, along with a detailed failure mode analysis, it is evident that the system achieves a practical equilibrium between real-time response and small object recall. Although overall performance matches the first benchmarks, our study shows that extreme scale variation and long-tail categories remain obstacles, so we suggest exploring knowledge distillation and efficient transformers for future improvements.

Key words: Deformable DETR; traffic sign detection; vehicle multi-object detection; small object detection.

目录

摘要	I
ABSTRACT	II
1 绪论	1
1.1 课题背景	1
1.2 目的与意义	2
1.2.1 研究目的	2
1.2.2 学术意义	2
1.2.3 工程意义	2
1.2.4 应用意义	3
1.2.5 可验证目标与评价口径	3
1.3 论文研究主要内容	3
1.4 国内外研究现状	4
2 关键理论与技术介绍	6
2.1 目标检测理论	6
2.2 多目标跟踪（MOT）基础	7
2.2.1 数据关联范式	7
2.2.2 ByteTrack 与 OC-SORT	8
2.2.3 时序一致性评价指标	9
2.3 评测方法与系统性能指标	9
2.3.1 检测指标	10
2.3.2 跟踪指标	10
2.4 可视化评测闭环与数据管线	11
2.4.1 落地字段定义（最小 Schema）	11
2.5 本章小结	12
3 需求分析与总体设计	13
3.1 检测系统系统概述	13
3.2 检测系统的需求分析	13
3.2.1 功能性需求	14
3.2.2 非功能性需求	15
3.3 检测系统总体设计	16

3.3.1 模块划分	17
3.3.2 数据流程设计	19
3.4 本章小结	20
4 系统的详细设计与实现	21
4.1 数据集构建与预处理	21
4.2 Ground Truth 可视化与标注一致性检查	23
4.3 Warm-start 跨帧引导机制的实现	23
4.4 在线关联与轨迹管理 (ByteTrack) 模块的设计实现	24
4.5 模型设计与配置	25
4.6 模型训练策略与实现	26
4.6.1 渐进式图像缩放策略	26
4.6.2 多数据源混合训练	27
4.6.3 训练超参数与加速	27
4.6.4 模型部署与系统界面	27
4.6.5 工程逻辑	28
4.6.6 界面设计	28
5 系统测试	29
5.1 测试环境与评价指标	29
5.2 跟踪实验	29
5.2.1 消融实验设置说明	29
5.2.2 MOT 评估指标对比	30
5.2.3 稳定性诊断指标分析	30
5.2.4 定性结果对比分析	31
5.3 检测准确性结果	32
5.4 系统性能测试	34
6 总结与展望	36
6.1 论文总结	36
6.2 未来展望	36
参考文献	38

1 绪论

1.1 课题背景

自动驾驶系统的感应部件通常依靠车上的摄像头提供的连续视频流，对车辆、行人、各种交通标志和其他道路使用者进行长时间、相对稳定且连续的定位与辨识。但是在实际的现实道路场景中，这些对象常常表现出小对象比例较高、对象间遮挡与密集交互频繁、光照状况复杂多变以及气候环境波动较大等特点，这些因素提升了目标检测和时序层面理解的总体难度^[1]。以交通标识为例，在进行分析时发现，其在原始图像中的面积占比通常仅为全部像素的 1%，甚至低于 1%。在此情况下，分析结果极易受到尺寸缩小、背景纹理干扰以及成像品质变化的综合影响。此外，大规模驾驶场景数据集进一步显示，不同地域、环境条件以及天气变化对算法的稳健性提出了更高的要求^[2]。

近年来，目标检测领域大致形成了两类较具代表性的技术演进路线，一类是以密集预测及后处理机制，也就是典型的非极大值抑制等策略，作为主要特征的实时检测体系；另一类则是以 Transformer 为核心结构，并将检测任务表述为集合预测问题的端到端方法范式，也就是 DETR 系列方法。DETR 模型以匈牙利算法为原理，舍弃传统锚框及非极大值抑制（NMS），令整体检测流程变得更为简练，不过最初的 DETR 模型仍存有几处瑕疵，即存在收敛速度低、对小目标缺乏敏锐度等情况^[3]。可变形态 DETR 模型在此基础上又加入了可变形态注意力机制，此机制大幅缩减了训练时所需的迭代次数，并且改良了小尺寸目标的探测能力。而且存在其他像 RT-DETR 之类偏重时效性的改良变种模型，它们在保留 DETR 架构的情形下，改善了速度与精准度之间的兼顾关系，这样的成果为后续的工程安排以及实际应用赋予了更具实用价值的基本保障。

在目标检测过程中，仅仅依靠单帧面的检测结果很难保证帧与帧之间连贯稳定，单帧面检测系统往往会存在轨迹抖动、目标身份 ID 频繁变更以及短时间内目标丢失等问题，所以本文采用强检测加轻量化关联的工程手段，并把跨帧查询引导当作后续持续发展的主要方向，系统经由跨帧信息利用形式和数据关联策略加强了时序上整体的连贯性，ByteTrack 算法就是把低分检测框也列入关联流程，这样做就减轻了由于漏检造成的轨迹中断情况^[4]；OC-SORT 算法在遮挡更为繁杂，运动状态更不稳定的场景下表现出更强的稳定性，该算法和 ByteTrack 算法一样，具备在融合高性能探测器之后得到较好的综合应用效果的能力。在目标检测评定体系当中，如果只是依靠 MOTA 和 IDF1 这些指标，那么就会出现无法统一衡量检测性能，关联质量以及定位准确性的情况，而采用 HOTA 这种评定指标，就可以全方位体现多目标追踪任务的实际状况，进而给系统改良给予更值得阐述，可供分析的量化参考^[5]。

在资料基础方面，自动驾驶领域已形成起覆盖面广，标注流程较为标准化的公开资料集，BDD100K 资料集就包含近十万段视频，其中涉及多种任务设置，丰富场景合成及各类评定标准，UA-DETRAC 资料集重点针对实际交通路口与城市主要道路环境，其内容涵

盖 100 段，共计 14 万帧带有遮挡情况，气候影响，车辆类型等属性标识的序列，适合用来综合考量检测与追踪能力^[2]。这些公开数据集给小目标场景，高密度目标场景以及跨帧稳定感知相关问题的研究给予了比较贴近实际情况的数据语料。

综上所述，针对自动驾驶视频流所处的复杂环境，当下急需一种能够在检测精度特别是小目标检测能力，时序一致性及即时性之间达成恰当兼顾的技术方案，即以 Deformable DETR 之类的端到端检测器作为主干，并融合跨帧信息引导机制，轻量级数据关联方法以及更具解释性的可视化评定循环，以此来进一步优化轨迹的稳定性，进而为后续的算法设计，系统创建和工程验证形成基础^[6]。

1.2 目的与意义

1.2.1 研究目的

本探究关注车用摄像头视频流场景里交通标志和车辆的联合识别任务，目标形成起兼顾检测精度，时间连贯性和即时处理能力的检测与追踪融合方案，凭借以可变形 DETR 为关键的端到端检测框架，再结合跨帧信息引导机制和轻量化数据关联技术，期望加强目标在连续视频流中的轨迹稳定性及其身份保留能力，最大幅度减小单帧检测方法因遮挡、尺度突变以及目标分布繁杂等情况的抖动与中断，以及目标间断和身份互换等状况。按照工程执行需求以及算法考量需求，本探究创建起涵盖数据收集，模型推断，目标关联，结果呈现以及视频回放等环节的闭合可视化考量系统，这个系统既能输出检测结果和追踪结果，又可更为直观、更具可再现性地展开巡视、比较和分析。

1.2.2 学术意义

本研究打算依靠 DETR 系列以“集合预测”作为核心特征的端到端方法范式，采用这个方法范式能够促使视频任务里时序建模步骤间的衔接更为高效稳定，凭借跨帧 query 引导机制和数据关联策略相互配合来加强模型跨帧一致性的维持能力，也能改良模型应对小目标情形时的稳健性与适应能力。文章将会从方法论角度针对小目标占比高，遮挡频繁发生，场景动态变幻快等常见难题展开系统的探究，在后续的考察当中着重剖析多尺度表现形式，先验初始化环节以及推断环节关联策略等主要影响要素，接着把它们与 AP, AP_small 以及 IDF1, HOTA 等评价标准结合执行分析，经由这些分析能够获取其具体影响^[7]，并且渐渐把分析出来的数据经由数据整合之类的方式塑造成为具备可重复利用价值的试验范例以及较为稳定的评价标准。从研究范式角度来看，本研究更多重视目标检测，目标追踪再到系统运行性能这种统一的度量关系，而且看重相关实验流程是否具有可重现性，这样以来，模型性能就不再仅仅停留在单一任务指标之上，而是更多着眼于检测结果，关联质量以及系统效率之间相互配合的整体状况，这样的研究路径能够给端到端视频感知方法的后续研究带来更具比较性价值的参照，也给予更具实用价值的经验支撑^[8]。

1.2.3 工程意义

本研究基于真实视频流场景搭建端到端原型系统，并且将数据采集、视频解码、模型

推理、目标关联、结果可视化以及时序回放等多个环节结合为一条相对稳定且连续的处理流水线，这种处理流水线可以有助于研发人员与测试人员更效率的定位问题、分析结果以及调优性能工作。在资源相对受限的应用环境之下，系统会进一步结合模型加速、批处理机制以及多进程并行等工程化手段，然后在检测精度、时序稳定性以及实时处理能力之间实现相对可控的平衡，同时还通过系统组件模块化，增强系统在后续的维护、迁移以及扩展过程中的灵活性与可操作性，这也是为了进一步面向车端或者边缘侧设备部署提供了较为切实且具备可落地性的技术路线。

1.2.4 应用意义

本研究形成的成果可进一步服务于道路交通巡检、智慧交通感知、行车记录分析以及园区与校园道路安全监管等多类实际场景，通过项目更稳健的小目标检测能力与更连续的轨迹维护能力，系统是可以在一定程度上提升对各类交通的要素的持续感知水平。同时使用时间轴回放及统计分析能力所构建的可视化工具，也是可以有助于开展事件检索、证据留存以及风险研判等工作。

1.2.5 可验证目标与评价口径

本研究计划处于开放数据集和自行收集视频片段结合的检测环境当中，把“可变形 DETR 与传统关联”当作基本方案，维持输入分辨率以及投入的计算资源不发生变化，尽力改善整体 mAP，并且目标达成 AP_small 改进 2%-5% 左右的效果，在系统性能层面，希望该系统于 720p 输入情况下做到每秒至少 25 帧的处理速率，把端到端的耽搁维持在 120 毫秒以内；对于 1080p 这种情形，则着重剖析耽搁和处理速度的关系，探究显存及 CPU 的利用状况，从而更为全方位地显示系统在不同分辨率时的运行情况，整个评定流程会依照统一的数据划分规则和统一的考量准则来执行，而且要给予减除实验规划和可以重现的实验程序代码，以此保障相关结论在分析时可靠，在实验时可被验证，在比较时具有可比性。

1.3 论文研究主要内容

本文主要围绕车辆摄像头视频流中的交通标志与车辆联合感知问题展开研究，并在保证方法具备可复现性及工程具备可落地性的前提下构建一套同时兼顾检测精度、时序一致性以及实时处理能力的整体方案。研究以 Deformable DETR 作为检测主干，模型检测面向小目标占比较高、遮挡现象频繁以及场景动态变化较强的道路环境，同时在研究过程中进一步探索在端到端集合预测范式中显式引入跨帧信息的实现机制，也就是利用前一帧中高置信度的检测结果对后一帧查询进行引导^[9]，从而实现跨帧 query 的有效传播，并且系统结合以 IoU 及运动一致性为主的轻量级数据关联策略来稳定目标轨迹与身份信息，以此缓解单帧检测所带来的轨迹抖动及中断问题^[10]。系统融合多尺度表示和先验初始化等方法，针对小目标，复杂光照或者气象场景执行加强操作，经由对符号体系，损失项训练以及推理流程实施统一阐述，保障该方法具备稳定性和可比性。

在底层架构的设计与达成当中，本研究形成起一套包含采集，解码，推理，关联，渲

染以及回放的全链路一体化原型，依靠此一体化原型直接创建起“算法—系统—可视化”深度衔接的考量闭环，该系统支撑帧级协作时同步映射边界框，类别属性，置信度以及 track_id 等参数，进而使得用户具备按照时间轴巡查，依照轨迹筛选以及导出片段的能力，这种机制能够加快问题定位，巩固失败案例的积淀，令原先黑盒化的实验过程具有更强的可解释性。

在性能评定这个核心部分，形成起了一种三维评价体系，该体系包含了检测精度，跟踪稳定性以及系统稳健性，它既包含像 mAP@0.5:0.95 和 AP_small 这样的常见检测指标，又把 IDF1, HOTA, 还有延迟，吞吐量，硬件资源占用这些端到端的性能表现纳入考量范围，在公开数据集和实际测量片段合成起来形成的场景里，针对跨帧引导，关联算法以及小目标加强等变量展开消融实验，研究团队深入剖析了夜晚，逆光，雨雾等恶劣环境情况。

由于实际落地的时候会陷入算力瓶颈，所以研究的时候又采用了混合精度，批处理，多进程流水线等提升性能的策略，经由细致剖析“精度-时序-时效性”三者的动态博弈关系，最后依照这些数据得出一套适合不同硬件参数的改良方案及参数设置指引。

1.4 国内外研究现状

面向自动驾驶场景的视觉感知研究，近年来主要沿着“目标检测—时序关联—系统可视化”这三条主线持续推进。就目标检测而言，基于卷积网络的密集预测体系，例如 YOLO 系列及其后续在轻量化设计、解耦头结构、多尺度增强以及蒸馏优化等方面的改进，已经在工业界形成了较为成熟的工程生态，也具备相对突出的实时性保障能力，与此同时，锚点机制以及后处理流程的依赖正在逐步减弱，Anchor-free 以及分类与回归解耦的范式也被越来越广泛地采用^[7]。另一方面，依靠 Transformer 的 DETR 端到端系列检测技术，经由集合预测和匈牙利适应重构了目标检测流程，这样的改良使得以 Transformer 为动力的 DETR 系列不再受限于传统的 NMS 和锚框设计，达成了整体上的改良目标^[7]；后来出现的多尺度建模，稀疏采样等改良方法，也能够改善其收敛慢，对小目标不敏感等问题，这些按照实际工程需求发展出来的即时化变种，既裁剪算法又保留了端到端原本的优点，从而缩短了同 YOLO 系列在推理时延方面的技术差距，当前，目标检测领域存在两种主要的技术路线——YOLO 系列和 DETR 系列，它们凭借自身的工程成熟度，全局建模能力等优势在该领域互相弥补，近些年不断发展，表现出参数高效化、结构深度复用这样跨范式的融合特点。

国内外学术界在应对交通标志分布密集又尺寸微小这个检测难点时，往往采用“双路发力”的研究策略，也就是从两个角度展开研究，首先在“特征空间”维度上，利用多尺度表示法，高分辨率分支设计法以及关键区域放大法等方法，从低层架构入手来提升极小目标特征的明显程度和类别可区分性，深入优化算法性能的时候，也会考察“数据层”存在的长尾分布情况及其域泛化能力，近些年行业一直在完善专门针对极小尺度目标，而且很容易被复杂背景影响的评定标准，渐渐推动该领域的研究重点冲破单类别检测局限，向着包含“车辆-行人-标志”诸多目标同时感知的综合体系发展^[11]。

在多目标跟踪领域实施工程部署时，大部分仍旧倾向于在线数据关联法，像依靠外观

特征来推动的 DeepSORT 及其各种变体就属于此类。这些变体在应对目标被遮挡情况以及跨摄像机场景的时候具有一定优势，还有一些纯粹着眼于几何信息和运动一致性这类的几何算法，当算力资源较少的时候，它们的速度优势会显现出来，运行稳定性也会更好，这个纯粹的几何类算法经由采用低置信度检测筛选逻辑，观测中心轨迹更新机制，匈牙利匹配法以及卡尔曼预测修正算法，针对轨迹断裂和 ID 切换这些长期以来一直存在的难题做了全方位的优化，于是使得这种纯粹的几何算法在复杂的动态场景下做到了对目标跟踪连续性大幅提升，而且，多目标跟踪评判标准的发展趋势在于由关注单个维度的传统指标慢慢朝着像 HOTA 这样较为全面的衡量体系靠拢，这种体系改变的好处就是能够借助更为精准的解耦分析，更好地体现算法在检测，定位以及关联这些环节之中深层次的结合程度，进而填补过去那些测度无法准确表现实际跟踪效果漏洞^[5]。当下的技术发展趋势能够清楚显示高质量检测结果对总体跟踪效能起着决定性作用，这种协同稳定的数据显示关联策略配合高效的时序建模手段，可以在极其复杂交通情况下维持目标运动轨迹的连贯性与逻辑一致性^[12]。

近年来，“检测—追踪一体化”这条端到端的改良路径表现出很强劲的发展态势，这项技术依靠以 Transformer 为关键的序列建模框架做到跨帧查询的循环利用，把检测和关联任务放在同一个改进目的之下一同去求解，去掉多余的由人实施的关联步骤，明显提升时序信息的表现能力^[13]。过在实际操作的时候，这种方法往往针对训练数据量，显存容量以及及时延上限这三个指标更为敏感。因此如何在真实系统中实现“学术指标表现”与“工程性能要求”之间的平衡，依然是一个非常关键的问题。也正因为如此，学术界与工业界逐渐形成了“端到端一体化”及“强检测+轻量关联”两条并行发展的技术路径，前者更强调方法范式的统一性以及潜在性能上限，后者则更强调实际易用性、实现复杂度以及工程可部署性。

业界觉得，系统达成与分析工具里的数据闭环和可视化分析属于系统很重要的部分，按照部分业界的研究和应用来看，仅依靠数值指标很难马上找出问题的原因，所以在设计代码的时候，要让系统把检测框，类别置信度以及轨迹 ID 等信息展示在播放器的时间轴上，并且这个时间轴要有交互功能能来回播放，而且在设计时还要进一步搜集，规划失败案例库，设置片段导出机制以及导出统计报表的功能，这样做就能促使数据，算法和系统相互配合，改善系统整体的工作流程，由于程序运行在资源有限的边缘车端环境里，所以得要思考在算力受限的情形下如何保证即时推理能力，怎样管理显存，多进程流水线以及异常复原机制能否正常运行，要把这些机制对应的指标列入到标准的考量和报告格式当中。

经由对国内外单目摄像头自动驾驶感知领域加以分析就能知道，当下检测模式、时间序列建模以及系统工程均有一定的基础，但在微小目标和恶劣天气条件下检测的稳定性，跨帧连续性长时间维持等方面仍大有加强之处，于是本文会依照这些实际难点，凭借依靠可变形 DETR 的核心检测框架，利用跨帧信息引导并采用轻量化数据关联方法，创建起一套既能做到高精度，时间稳定性也可达标而且具备即时性能的联合感知原型，并把这些指标放在统一的评价体系以及可视化的评价循环里面实施系统的验证。

2 关键理论与技术介绍

本章将介绍目标检测与多目标跟踪领域的相关理论和技术基础，并明确系统设计所依赖的术语框架，为后续方法章节提供支撑。

2.1 目标检测理论

DETR (Detection Transformer) 模型把目标检测转变成集合预测问题，依靠一对一的适应策略，从源头缩减多余检测结果的出现^[7]。具体来讲，模型在输出端预先设定好一定数量的预测查询，让各个查询自己分别预测边界框或者“无目标”类别，而且凭借匈牙利算法创建预测集和真值集之间的全局最优双向适应关系，这个机制使得每个真实目标只能对应一个预测输出，这样就在结构层面摆脱了对传统 NMS 后处理的依赖，所以该模型既精简了检测流程又维持了框架的高一致性，在系统完成适应之后，系统会凭借包含分类损失（交叉熵或者焦点损失），边界框回归损失（L1 距离和 GIoU 损失）加权而成的匈牙利损失（Hungarian Loss）来引导模型展开训练，经由对预测-真值对执行逐一比较以计算梯度，从而做到端到端的参数改良。这种做法省却了锚框机制以及后续无谓去除多余物的环节，径直针对集合预测损失实施全方位改良，这就使得模型在复杂环境当中具备更为出色的整体建模能力和结果提升水平^[7]。

但是，在初版的 DETR 有两个主要问题，一是训练收敛缓慢（需要数百轮训练），二是对小目标检测效果不好。而原因在于其全局注意力机制对所有图像特征都一视同仁，导致模型难以及时聚焦于小目标区域；与此同时，DETR 仅在单一尺度的特征图上执行注意力计算，所以导致了分辨率较低的小目标信息容易被淹没。前面提到存在一些局限性，Deformable DETR 这种改良框架就出现了，Deformable DETR 有个重要的改变之处就是采用了可变形多尺度注意力机制，这样做的好处是，查询元素就不会漫无目的地去遍历整张特征图上的每一个像素点了，而是紧紧锁定到每层特征图里那些非常有代表性性的稀疏采样点上，确切来讲，Deformable DETR 使得目标查询能够在临近参考点的小范围内获取关键特征信息，而且还能跨越不同尺度来做稀疏注意力聚合操作，这个模型既减轻了计算负担，又大幅改善了对于小目标的检测能力^[4]。这种稀疏采样极大地简化了注意力计算的复杂度，还加快了模型整体的收敛速度，靠多尺度特征融合来加强模型对小目标的感知效果。有研究已经指出，Deformable DETR 将原始 DETR 数百轮训练才能收敛的难题，压缩到 50 轮以内，并在 COCO 小目标上取得更高的 AP_{small} 指标^[8]。

虽然引入可变形注意力后 DETR 在精度和速度上都有提升，但 Transformer 检测器整体推理的开销依然较大，并且在一定程度上削弱了端到端设计在实时检测中的优势。在急需及时性的时候，出现了 RT-DETR (Real-Time DETR) 这一具备及时性能的端到端 Transformer 检测器，它经过许多全面的架构改良，填补了 Transformer 架构和像 YOLO 这样的传统及时 CNN 检测器之间的性能差距，在总体设计方面，RT-DETR 的关键改良之处就是采用高效混合编码器替代原有的结构，而且分离了同一尺度内的特征交互与跨尺度的融合流程，这样就缩减了许多多余的计算量，在这种混合编码策略之下，可以有效地去除

计算上的多余之处，又解决了多尺度特征交互造成的算力难题，非常直观地改善了编码阶段的总体执行效率。另一方面，RT-DETR 采用了不确定性的最小查询选择策略，在解码器初始查询的形成时，综合考虑目标位置线索和类别置信度，做到了检测准确性逐步加强。该架构还具有一个亮点，即无需再次训练模型，就能经由动态调整解码层数来灵活兼顾推理速度和精度，给不同算力约束下的部署带来很高的工程适应性，经过前面的加强以后，RT-DETR 既保留了 Transformer 模型高检测精度，不需要 NMS 后处理这些优点，又明显加快了推理速度，有些研究表明，在 COCO 上，Res50 模型的报告帧率为实时帧率，mAP 高于 60。总的来说，DETR 系列模型从原始 DETR 到 Deformable DETR 再到 RT-DETR，不断解决收敛速度、小目标检测和实时性能方面的问题，使基于 Transformer 的检测器逐步逼近甚至部分超越了传统 CNN 检测器的实用性^[15]。这些迭代和改进让项目在设计交通标志与车辆多目标检测系统时选择合适模型提供了强有力的依据。

2.2 多目标跟踪（MOT）基础

在公路场景中检测并跟踪多辆车辆，每辆车用唯一 ID 标识并标注类别及置信度。跟踪算法需要在连续帧之间保持同一对象 ID 的一致。

2.2.1 数据关联范式

多目标跟踪通常采用“检测—关联”的范式，也就是先对每帧进行目标检测，然后在帧间关联这些检测以形成连续轨迹。关联过程的核心关键点是在于判断不同视频帧中的检测结果是否对应同一目标对象，而这一判断本身涉及多种策略及算法。当前较为常见的方法主要包括基于运动模型的匹配方式、引入外观 ReID 特征的关联方式，以及面向全局优化的数据关联方法。

其中，基于运动模型的匹配是当前多数在线跟踪器普遍采用的一类技术路线，其基本思想是在于利用匀速直线运动的原理来假设对目标的未来位置进行预测，例如通过卡尔曼滤波器对每个目标的状态变量，也就是位置及速度等信息，进行递推预测与更新，随后再将当前帧中的检测结果与上一帧所得到的预测位置进行比较，并且借助 IoU 重叠度或者欧氏距离等度量方式计算匹配代价，在此基础上，再利用匈牙利算法在总体代价最小的约束条件下完成检测结果与已有轨迹之间的一一分配，这种方法最早应用在 SORT 算法中^[12]，并且正因为其简单计算开销较低以及运行效率较高，后来被广泛用于各类在线多目标跟踪任务之中。但是根据研究者表明，单纯依赖位置信息进行匹配，在目标外观较为相似或者场景中出现短时遮挡时，往往更容易产生关联错误，进而影响轨迹的稳定性与身份一致性。

而“引入外观 ReID 特征”则是为了提高关联鲁棒性，后续方法如 DeepSORT 是在上述运动预测匹配的基础上融入了视觉外观特征^[12]。通过为每个检测提取卷积或深度学习的 ReID 嵌入向量，在匹配代价中同时考虑检测框之间的外观相似度（如余弦距离）。当纯几何位置不足以区分目标的时候，外观特征就可以同时辅助识别同一目标。外观 ReID 在行人跟踪等领域也取得了一定的效果，但是在拥挤的场景下由于目标外观高度相似且遮挡频繁，其辨别力可能会下降，甚至会引入错误匹配^[16]。

全局数据关联则是除了逐帧在线匹配外，还有一些方法尝试在更长时间窗口甚至全局进行关联优化，例如通过网络流或近似求解最大权匹配，将多帧的信息一起考虑，以减少局部决策错误对整体轨迹的影响。不过全局方法通常计算复杂度高或需要预先知道整个序列信息，实时性较差，在实时系统中应用有限。

2.2.2 ByteTrack 与 OC-SORT

近些年来，MOT 挑战赛中许多检测后跟踪算法表现良好，ByteTrack 和 OC-SORT 是两种比较有代表性而且较为轻巧的追踪器，这两种算法都是在 SORT 框架基础上加以改良得到的，不过它们各自侧重之处存在差异。

ByteTrack 的核心观点是，并非所有跟踪误差都是由于关联算法自身存在漏洞所致，关键在于检测阶段高置信度阈值过早地筛选掉了一些真实但置信度较低的目标，使得轨迹在半程帧出现频繁断开现象。针对此难点，ByteTrack 采取了一种被称作“两阶段”的匹配方案，即先用高置信度检测成果去跟已有的轨迹做初次对接，然后把那些未能建立起联系的轨迹再与低置信度的检测框做第二次尝试，从而尽量全面地运用全部检测信息去保存时序上的连贯性，从这个策略本身来看，它就是把所有检测输出都当作潜在关联的对象，即便碰上模型置信度因遮挡而急剧下降这样复杂的情况，照样可凭借多层次的关联做到对目标不停止追踪，这个机制不但能在某种程度上改善检测器性能起伏的问题，而且从核心上加强了系统在极端环境中的检测召回率及其轨迹稳定性。实验结果表明，ByteTrack 在 MOT17 等基准数据集上取得的 MOTA 及 IDF1 分数处于领先水平^[4]，ByteTrack 具有最大限度提升目标“检测-跟踪”覆盖率的优势，比较适合检测能力较强又想防止漏检的场景，不过因为采用了低置信度框，所以该算法偶尔可能把误检纳入轨迹当中，实际应用时仍需靠轨迹经营策略（比如短轨迹过滤）来缩减误检所造成的不良影响。

传统 SORTA 存在不足之处，即非线性运动及长时间遮挡情况下其鲁棒性有所缺失，为解决此问题，OC-SORT(Observation-Centric SORT)提出一种以观测为核心的改良方案，OC-SORT 重点关注在无需依靠外观特征的情形下，经由观测重插(ORU)和观测动量(OCM)两个核心模块维持轨迹在动态剧烈改变时的稳定性。ORU 机制使得系统可在重建轨迹之时按照过往观测结果推测丢失时段的“虚拟位置”，进而弥补和纠正卡尔曼滤波不断向外推算所累聚的误差；OCM 则是在考量配对成本的时候把运动方向一致性的条件纳入考虑范围，这样做很好地改善了由于速度估算过程产生噪音而导致的错误绑定情况，凭借这些改动，该算法既保存了低时延又随时的特点，又极大地优化了对复杂运动建模的准确性，在 MOT20 这种高密度场景数据集上出现的出色 HOTA 和 IDF1 指标，清楚显示了它在维持目标身份连贯性方面的技术优势^[10]。综上所述，OC-SORT 比较适合目标重叠现象突出，遮挡频繁发生的，而且对 ID 切换难以容忍的观察环境。所以实际应用过程中，如果系统重视最大程度下缩减漏检数量并且守住较高的综合准确率，那么可以选用 ByteTrack；要是任务侧重于减小 ID 切换次数，做到追踪轨迹稳定，那么 OC-SORT 将会是更好的选项。

2.2.3 时序一致性评价指标

为了评估多目标跟踪算法在检测准确率和身份一致的综合表现，学术界提出了多种评价指标，常用的包括 MOTA、IDF1 和 HOTA 等：

MOTA (Multiple Object Tracking Accuracy, 多目标跟踪准确率) 综合考虑了漏检 (FN)、误检 (FP) 和身份切换 (IDSwitch) 三类错误。其计算公式如公式 2-1 所示。

$$MOTA = 1 - \frac{FN+FP+IDSW}{GT} \quad (\text{公式 2-1})$$

MOTA 指标把 GT (真实目标总数) 当作参照，会更多地表现检测维度的整体效能，但在现实当中，模型漏检和误检会给这个数值的波动带来很大影响，而且 ID 切换只是被当作一个错误点，所以它在稠密目标环境里就变成了检测召回率和精度的一种量化表现形式，对待目标身份连续性就比较薄弱。

IDF1 (IDF1-Score) 与之相补，它专注于考量目标身份在时序流中持续保留自身的能力，IDF1 会结合 ID 精确率 (ID Precision) 和召回率 (ID Recall)，以此判断目标身份能否恰当守住身份标识的检测比例。当执行全局预测轨迹与真值轨迹相契合的操作时，这个指标会统计 ID 维度的精确度和召回率，并计算它们的调和平均值 F1，这样做可以使模型在长跨度序列里锁定同一个对象的能力表现得更为直观，相比于重视瞬时检测质量的 MOTA 而言，IDF1 重视长期身份的稳定性，这种关注有效地填补了前者应对 ID 频繁变换问题时存在的不足。

HOTA (Higher Order Tracking Accuracy, 高阶跟踪准确度) 是一种近年被提出的综合评定指标，该指标希望达成对检测性能和关联性能这两方面考量需求的兼顾^[5]。HOTA 经由把检测正确率 (Det A) 与关联正确率 (AssA) 分离，然后对它们执行调和平均运算以此得出总的得分。在这个计算过程中会考虑不同 IoU 阈值下匹配情况，并综合各阈值对应的结果形成最终得分。相较 MOTA 和 IDF1 都更偏重单一维度的评价方式，HOTA 试图提供对目标拾取 (检测) 和轨迹连贯 (关联) 更全面客观的度量。在实践中，发现 HOTA 对 ID 开关和漏检同样敏感，也正因如此，被大众认为能更好地反映跟踪算法的整体有效性。

此外，还有一些用于分析跟踪错误的辅助指标，例如轨迹断裂 (Fragmentation) 是指单个真实目标的跟踪轨迹被算法分成多段的次数，ID 切换次数指轨迹的 ID 发生改变的累计次数等。一般来说，希望轨迹断裂和 ID 切换越少越好，因为它们的减少往往会提升 IDF1 和 HOTA 等指标。综上，不同指标从不同角度衡量跟踪性能，研究者应综合参考，以全面了解算法的长处与短板。

2.3 评测方法与系统性能指标

为全面检验本系统在算法效果与工程实现两方面的表现，项目从学术评价指标 (检测与跟踪) 以及实时系统运行指标两个层面进行度量与分析。基于此，本文建立如下指标体系，并在后续实验中据此统一报告与对比。

2.3.1 检测指标

针对目标检测效能的量化评估，本研究严格遵循 COCO 评测准则，通过构建多阈值与分尺度的综合指标体系以同步衡量定位精度与召回能力。

(1) $mAP@0.5:0.95$ 即平均精度均值，此范围以 0.05 为间隔包含 0.50 到 0.95 之间的 IoU 阈值，在这些阈值处分别计算 AP 值并求和，其关键意义在于概括体现模型于不同重叠程度要求下的稳定表现状况，经由此种跨越梯度的采样运算方法，该指标既能够兼顾高 IoU 限定下像素级别的定位精准度，又可顾及低 IoU 限度下目标选取的功能，而且能有效地规避由于单一阈值评定可能造成的性能偏差。

(2) AP_{small} 即小目标平均精度，COCO 会将目标按边界框面积划分为小、中、大三类，其中面积小于 32×32 像素者归为 Small。 AP_{small} 统计小目标上的 AP，用于评估模型在小尺度目标上的特定表现。在道路交通场景中，交通标志多属于小目标，因而该指标尤为关键。

(3) AP_{50}/AP_{75} 。为便于直观对比，亦报告单一 IoU 阈值（0.50 与 0.75）下的 AP。前者条件宽松、数值通常较高；后者要求更严格定位，数值相对较低，可辅助分析定位精度上限。

2.3.2 跟踪指标

在多目标跟踪部分，本文采用同时关注检测覆盖与身份一致性的主流指标，并辅以事件级诊断项，以获得对时序稳定性的全面刻画。

(1) MOTA（多目标跟踪准确率）。综合考虑漏检（FN）、误检（FP）与身份切换（IDSW），定义见第 2.2 节。其计算如公式 2-2 所示。

$$MOTA = 1 - \frac{FN+FP+IDSW}{GT} \quad (\text{公式 2-2})$$

公式以 GT（真实目标总数）为参照时，MOTA 更侧重于考量检测维度的覆盖情况，特别是在目标密集的场景里，FN（漏检）和 FP（误检）的变动会给分数带来很大的影响，这样就可能隐藏住潜在的关联质量差别，从而使得 MOTA 变成一种检测器性能的附属的指标。

(2) IDF1（IDF1 分数）是衡量身份持续一致性的关键指标，它依靠完整序列的全局适应情况去计算 ID Precision 和 ID Recall 的调和平均值，当 MOTA 处于较高水平而 ID 频繁切换时，这个指标往往表现为小数值，于是就同前面那个一起做到了有效的综合评定作用。

(3) HOTA（高阶跟踪准确度）这个指标会把检测正确率 Det A 和关联正确率 AssA 解开，然后取它们的几何平均值，这样就可以同时衡量目标拾取能力和轨迹连续性能，它的计算过程包含针对很多 IoU 阈值的适应聚集，当 MOTA 和 IDF1 评价结果有矛盾的时候，它可以给出比较权威的综合判断。

(4) 轨迹断裂次数与 ID 切换次数属于诊断性指标，要统计轨迹中断后再重建的次数，也要统计轨迹 ID 改变的次数，前面的状况大多由漏检造成的跟丢引起，后面的则与错误

关联所致的身份混淆相对应，二者如果减小，一般会导致 IDF1 和 HOTA 同时得到提升。

2.3.3 系统性能指标

从工程执行的角度来讲，文章针对即时性，吞吐量以及资源占用等情况创建系统运行指标，而且把异常状况下的稳定性归入整体评定范畴。

(1) 端到端时延 (Latency) 指从收集数据直至结果渲染完成所历时延，此过程中牵涉图像获取，模型推理，数据关联以及可视化描绘等多个阶段，一般而言，端到端时延低于 100 毫秒即近乎处于即时状态，文章会单独列出帧处理时延和总体时延情况，并尽量将其维持在合理区间之内。

(2) 吞吐量 (FPS) 这一指标用作衡量系统持续处理能力的准则，其能够综合体现模型的推理速度，数据关联开销以及底层并行能力之间的协同效率，在系统开展即时观测或者显示相关任务期间，该参数一般要保持在不低于视频输入流原本帧率的水准，从而保障视觉反馈的即时性并防止出现处理链路上的堆积现象。

(3) 资源占用方面，系统要随时监测并记录 GPU 显存峰值，CPU 利用率以及系统内存的动态变化情况，因为 Transformer 类检测器对显存需求很严格，而且可视化渲染和数据存储环节也会消耗部分计算资源，所以在边缘计算环境里，本方案经由深入考量性能权重和资源配额，能在有限的算力之下做到系统稳定与检测效能的良好兼顾。

(4) 异常复原能力这个参数能够考量在压力负载很大以及出现故障的时候，利用注入故障，压力检测等手段，来考察系统对于帧丢失，进程异常或者网络抖动等情况自身的复原能力和告警反应，在系统正常运行时，应该能在断流之后自动重新建立连接，当 ID 顺序混乱时会启动重初始化机制，而且凭借局部时间窗口来限制故障的蔓延，这样就能把异常造成的不良影响降到最低限度^[17]。

系统侧会统一采用“均值+p95 延迟”这种合成形式，当输入分辨率和 batchsize 都固定下来（默认为 1）的时候，经由模拟断流，进程重启这些极端情况来得到检测数据，这样就可以给不同算法方案之间的横向比较赋予一个标准化的参照。

2.4 可视化评测闭环与数据管线

系统围绕“采集—推理—关联—存储—回放”构建闭环：实时采集视频帧；将帧送入检测器得到 (b, c, s) ；在线关联赋予 trackID；将叠加了 b, c, s, ID 可视化结果进行绘制渲染，同时把结构化结果写入存储；前端部分则提供时间轴回放、轨迹尾迹叠加展示、按 ID 及类别进行筛选，从而帮助使用者更快速地定位问题片段，更准确地复现实验现象，并逐步形成可积累、可复用的知识沉淀，进而为参数整定及工程优化提供更直接的支撑^[17]。

2.4.1 落地字段定义（最小 Schema）

结果记录统一为 $(frame_id, ts, class, b, s, track_id)$ ，其中 b 采用 (c_x, c_y, w, h) 表示；书签（问题片段）记录为 $(start_t, end_t, tags)$ ，用于复测与报告生成的片段化管理。

2.5 本章小结

本章主要站在系统达成以及方案再现的层面，深入剖析 DETR 架构里的集合预测机制和稀疏多尺度注意力部分，再加上对在线 MOT 数据关联形式及其轻量化途径实施概括叙述，这样就创建起一个包含检测，追踪以及系统效能的统一评定标准和相关符号集，然后确定出可视化的评定循环和数据管线塑造所需要的主要因素，这些理论积淀和技术准则一方面给后面涉及整体规划，模块制作和检测评定的篇章赋予牢靠的工程项目保障，另一方面也为后面采用跨帧 Query 引导机制和小目标提升分支之类的高级改良构筑更新换代的基础，进而按照当前的架构不断促使算法效果和工程实际意义一起得到提升。

3 需求分析与总体设计

3.1 检测系统系统概述

本系统依靠 DETR 模型创建而成,它是个交通标志和车辆的多目标检测及可视化的平台,主要目的在于给自动驾驶场景赋予即时性目标检测,目标追踪以及结果可视化的能力,利用 Streamlit 框架达成的前后端一体化设计,把深层检测算法同交互式 Web 界面紧密结合起来,给研发和测试人员给予了一种直观的分析与比较环境,检测系统的核心任务就是完成好系统的核心使命,即解决交通场景里车辆和标志检测的精度问题,一方面要保障跨帧的连续性,另一方面要用叠加渲染的形式表现检测框,运动轨迹和类别属性,进而给算法的闭环验证和调试赋予稳固的工程支持^[17]。

系统的整体结构包含目标检测模块、目标跟踪模块、可视化表现模块、用户交互控制模块等等很多相互配合的功能模块,这些模块一起承担起从视频数据读取开始,经过目标识别与跟踪,直到结果渲染以及用户交互这样一体化的处理过程。系统具备的关键能力大多表现在针对交通场景里的各类目标实施即时检测和识别上,依照检测结果做多目标跨帧追踪,而且还能在 Web 页面上动态描绘目标边界框,类别标识以及运动轨迹之类的信息以供用户阅览,系统另外给予视频播放控制和数据筛选功能,使得用户能比较轻松地执行诸如视频回放,暂停播放,选定关注的目标类别,标注感兴趣的帧并截图保存之类的操作。

在实际运行流程当中,用户利用浏览器端加载驾驶视频之后,后台马上开启依靠深度学习的推断引擎,针对每一帧画面自动识别其中的车辆和交通标志,而且会把得到的边界框以及置信度信息按照先后顺序建立联系来赋予每个目标独一无二的编号,前端界面接着会及时反馈经过处理过的视频流,它会在原本的画面基础上鲜明地层叠上多种色彩标识的检测框和动态轨迹,这样就能清楚看出车辆的移动方向以及标志的分布情况,这个期间,分析人员能够凭借时间轴控件做到精确定位,再结合分类筛选功能关注到自己想要的目标,当一些重要事情发生的时候,还可以利用书签记录和截图存证功能保留住关键的数据,依靠这些东西创建一个交互性很强而且逻辑完整的算法评定支撑平台。

3.2 检测系统的需求分析

确定了系统对象,应用场景以及约束条件之后,本研究详细定义了可视化平台的逻辑边界和验收标准,经由深入剖析功能性与非功能性需求,使得系统能够准确适应道路交通视频环境下的算法验证与显示任务。它的输入端把单目 RGB 视频当作核心载体,既默认支持离线文件,又包容本地摄像头和 RTSP 流等拓展模式,输出端融合了叠加检测框,类别属性,置信度分值以及跨帧运动轨迹,并具有导出结构化结果数据的能力,这个系统的核心用户群定位在算法研发与测试人员身上,希望帮助他们达成漏检误检识别,目标 ID 一致监测以及参数更新比较等常见任务,而且给予截图,标注视频和日志文件之类的报告资料支撑。这种非常符合实际研发逻辑的需求设置,突出优化了系统在工程执行过程中的功能指向性及其实用价值,进而给后面模块的细致开发形成了清晰的目标引导。

3.2.1 功能性需求

根据对自动驾驶场景下感知与可视化需求的调研情况，系统应满足以下的主要功能要求：

(1) 多目标检测

能够对输入的视频帧进行目标检测，识别出其中的车辆、交通标志等对象，并返回每个目标的边界框位置、类别标签以及置信度等属性。检测模型采用基于 Transformer 架构的 DETR 算法（具体使用改进的 Deformable DETR 变体，以提升对小目标和密集场景的检测性能，确保对交通标志这类小尺寸目标有较高检出率）^[7]。此外，已有研究针对极端天气条件下的交通标志检测提出了改进算法^[14]。

(2) 跨帧目标跟踪

在逐帧检测结果的基础之上，系统进一步实现对目标的多目标跟踪功能，也就是说，系统需要在视频连续帧之间对检测结果进行关联与匹配，并为同一实体分配且持续保持唯一的身份 ID。跟踪模块则需要综合依据目标之间的位置重叠关系，从而尽可能保证目标 ID 在整个视频处理过程中保持稳定且不发生无意义变化。这样一来，系统便能够生成每一个目标随时间连续变化的轨迹数据，并进一步支持后续的轨迹可视化展示及行为分析工作^[17]。

(3) 轨迹路径展示

此功能重点在于把跟踪模块连续处理时所获历史位置信息经由可视化叠加形式投射到视频画面上，轨迹路径显示模块会在图像上勾勒彩色线条以动态表现车辆的前行路线，进而帮助用户准确把握目标的运动趋向及其位置变化规律，对于交通标志等较为固定的物体，其轨迹大多体现为不断标注所在的空间坐标，这样做的好处一是在于提升了场景里既有目标和新出现目标之间的区分度，二是在于给后面的行为模式分析以及感知成果解读赋予了直观的数据支持。

(4) 检测结果叠加显示

前端界面要随时渲染每帧的感知输出，这样才能保证边界框（锁定目标区域），类别标签（界定车辆或标志属性），置信度数值以及跟踪 ID（区分不同实体编号）一同叠加在原始视频上，为保证视觉识别有效率，系统应针对不同类别或者特定 ID 的显示样式，在色彩，线型和填充方式方面作出差异化设置，从而即便处于复杂背景之下也仍然有着很高的区分度，进一步帮助用户迅速查找并分析目标状态。

(5) 类别筛选与视图控制

系统经由集成交互式控件，给予用户按照目标属性动态过滤显示内容的能力，使得用户可以在仅显示车辆，仅查看交通标志或者全局监测模式之间随意切换，还能够隐藏诸如轨迹线之类的特定元素来改善视觉集中度，结合视频播控组件所赋予的播放，暂停和停止功能，用户凭借进度条或者时间轴就能达成对指定时段的秒级跳转，在此期间，系统会及时更新渲染帧及其对应的检测统计数据，保证交互反馈的同步性。

(6) 书签标记与事件记录

在视频回溯的时候，用户能够对关键帧或者感知异常执行“添加书签”的操作，这个

过程中会记录下精准的时间戳，而且还能加上自定义备注，这样就把零散的即时事件变成了可追溯的结构化列表。这种机制既能够让分析人员经由点击标签立即跳转到相关部分做复审，又能够启动异常截图功能来做到证据链在离线情况下的保留，生成的截图文件会自动包含时间戳等关键元数据，从而保证后续的问题追溯以及场景再现是准确的。

(7) 结果数据存储与导出

系统在内存里会对已处理过的帧以及其标注元数据执行高速缓存，从而保障长历时任务分析时的效率，这样用户在回放或者局部复查的时候就能立刻获取相关的内容。凭借这个数据基础，平台可以将含有检测框和运动轨迹的标注视频加以封装导出，也可以把目标属性数据存储为日志或者结构化表格的形式，这既极大地简化了结果复审和离线分析的操作步骤，又给后续感知算法的性能改良以及多版本之间的比较赋予了可信的数据支撑。

3.2.2 非功能性需求

除了上述核心功能，本系统在性能、部署和可维护性等方面也有如下要求：

(1) 实时性与低延迟

系统应当能以接近实时的速度处理视频帧，以保证检测结果及可视化展示结果能够与视频播放过程基本保持同步，或者仅存在较小且可接受的延迟。在理想的情况下，有 GPU 硬件加速时系统处理速度可达到每秒 20~30 帧的处理能力，从而使输出帧率接近原始视频帧率。与此同时，系统对于单帧的处理延迟应尽可能低（例如 100ms 以内），以使用户在交互拖动或跳帧时可以迅速呈现结果。

(2) 稳定性与可靠性

在长时限运作和大规模数据处理的情形下，系统要保持很高的稳定性，不能出现内存泄漏或者程序崩溃之类的隐性问题，而且要为异常输入以及极端工作状况创建起完善的防错体系，这样才能保证所有没有处理的异常都被有效地识别出来。本平台采用断点续播和误操作复原之类的逻辑以改善用户交互的流畅度，在承受频繁调整进度条或者快速转换筛选设置的压力考察时，仍然能够达成画面对接的平滑转换以及时间顺序结果的精确对应，进而既保证核心感知任务连贯又改良了系统的交互容错能力。

(3) 易部署性与跨平台

本系统前后端依靠 Streamlit 框架创建，这种前后端一体的架构给系统带来了很好的部署便捷性，应用以 Python 脚本的形式被高度封装起来，用户完成依赖库设置之后，只需执行单条启动指令就能激活环境，完全避开了传统 Web 服务所必要的复杂服务器调优流程，这种轻量化的设计最大程度减小了开发者和检测人员在不同环境之间的迁移难度，而且代码具备对 Windows 和 Linux 等主要操作系统原生的适应能力，使得这个平台能在各种硬件架构下做到即插即用并迅速投入使用。

(4) 资源占用与性能优化

DETR 这种深度学习模型做推断的时候得消耗海量计算能力，所以系统底层逻辑要深入改良资源调度，首先调用 GPU 的并行计算集群来加快负载较高时的特征获取速度。而

且在只有 CPU 算力这种相对局限的情况下,经由批处理合并或者轻量化剪枝等方法尽力填补即时性方面的不足^[18],系统另外形成了一种细致的内存守护机制,也就是每完成一帧处理任务就要立即归还多余的缓存,对于轨迹存储架构也要做低延迟化处理,还要在前端传送阶段凭借动态调节图像压缩比例或者渲染分辨率,在视觉清晰程度与画面连贯性二者之间做到动态兼顾。

(5) 可扩展性与可维护性

架构设计的扩展性对于保障系统的生命时段十分关键,本平台采取高度模块化的组织形式,可做到检测模型在 DETR 各版本之间流畅转换,让跟踪算法轻松升级到融合 ReID 特征的高级方案。此类解耦设计既保留诸多交互控件及数据显示接口,又凭借明晰的模块界限和标准的数据协议达成了高内聚低耦合的代码框架,这样即便感知能力不断更新,可视维度不断扩充时,仍能守住逻辑清晰度并维持高效的维护速度,从而有效地减小后续二次开发的工作负担。

(6) 易用性与交互友好

作为面向研发人员的可视化分析工具,系统还应关注用户体验。本系统的界面布局应简洁明了,各功能模块及控件的标识应当明确清晰,相关使用说明也应保持足够直观,使用户无需复杂培训即可上手操作。前端的交互流程还应尽可能贴合研发人员的实际使用习惯。总的来说,良好的易用性不仅能够提升研发人员使用本系统进行分析与验证的整体效率,也能够一定程度上降低工具使用门槛,从而使本系统更容易推广到更广泛的自动驾驶测试与验证场景之中。

3.3 检测系统总体设计

本系统依靠 Streamlit 框架达成前端显示和后端处理逻辑的紧密融合,凭借该框架具备用纯 Python 创建交互式界面的能力,免去了传统架构中复杂的异步通信机制和繁杂的状态守护。此框架可在服务端即时运行脚本,并动态传递执行结果,这样的机制使得算法模块和交互界面在同一个进程中紧密协作,由底层框架自动维持界面组件和后端逻辑之间的交互联系,从而大幅简化了工程开发的复杂程度,从图 3-1 可以看出,整体架构的核心部分是经由数据输入层,算法处理层和可视化交互层横向叠加形成起来的,数据输入层着重关注视频序列的采集与预先处理,算法处理层担负模型推断与时序追踪等关键计算任务,而可视化交互层则负责像素级别的结果渲染以及对用户操作作出反应。以这个核心逻辑为依循,系统进一步生成起包含表现层,应用层,感知层,可视化层以及数据导出层的全面层级体系,特别是感知层内部深入融合了预处理,目标检测,多目标追踪以及后处理这些关键模块,各个功能层级经由精准的数据流和控制指令做到相互结合并协同运作,从而促使即时视频感知和交互式显示任务得以高效率地执行,它的整体设计方案图便是图 3-1 所示的内容。




图 3-1 系统总体设计图

3.3.1 模块划分

根据功能和流程，系统内部划分为若干模块，模块结构设计如下：

(1) 模型加载与推理模块

本模块负责初始化和管理工作 DETR 目标检测模型并提供推理接口。该模块在系统启动时会把模型加载到内存和 GPU 显存，然后再对输入视频中的每一帧图像通过调用模型进行目标检测推理，并输出该帧的检测结果列表。系统为了适应多类别交通目标检测，因此本模块使用的模型可能需要经过对交通标志数据集的微调，使其能够识别包括限速牌、停车牌等在内的标志类别。除此之外，模块还需要支持按照实际需求调整检测阈值等参数，并在运行过程中保持模型实例的高效推理。

(2) 视频读取与解码模块

承担视频数据源的读取和逐帧解码工作。通过 OpenCV 或其他视频处理库，模块将输入的视频文件逐帧读取成图像帧（numpy 数组），并按顺序提供给后续处理。该模块考虑视频的帧率和分辨率，对每帧的读取进行适当的延时控制，使处理节奏与原始视频时间吻合。同时这里也是播放控制的切入点：当用户选择暂停或跳转时，视频读取模块需要配合停止或跳至指定帧位置读取。模块在读取时还可对帧进行必要的预处理（例如调整大小以适配模型输入要求，颜色格式转换等）。

(3) 多目标跟踪模块

用于维护和更新视频中出现的所有目标的跟踪状态。它接收检测模块输出的当前帧目标列表，与上一帧的目标状态进行匹配关联。跟踪模块内部通常采用卡尔曼滤波预测和匈牙利

牙利算法匹配（类似 SORT 算法），或者结合目标外观特征（类似 DeepSORT）以提高匹配准确率。每当一个新的检测目标无法与已有轨迹匹配时，创建一个新轨迹并赋予新的 ID；匹配上已有轨迹的则更新轨迹的最近位置；长时间未匹配上的轨迹则终止。模块输出当前帧的目标清单（附加 ID），并维护一个全局的轨迹记录结构，用于存储每个目标 ID 的历史位置序列。这些轨迹数据将用于轨迹线绘制和提供高级行为分析。

(4) 可视化绘制模块

该模块重点把抽象的检测与追踪输出转为成直观的视觉反馈，它经由在视频帧上动态叠加标注信息来做到这一点，这个模块的核心逻辑在于提取各个目标的类别属性，追踪 ID 等元数据，并利用图形绘制库执行可视化渲染。当系统开展绘制任务的时候，系统会给不同的实体分配具有很高识别性的色彩方案，在边界框附近也会同时标注类别名称和标识文本，如果有历史位移数据，就会用折线或者曲线去连接历史质心，从而精准表现其运动趋势，这个渲染过程会对边框线宽，字体大小以及轨迹透明度等样式参数展开层级化管理，这么做就是为了保证标注内容在复杂驾驶场景下既清晰又美观，等图像处理完毕之后，得到的帧会被进一步编码成 JPEG 等前端可识别的格式，以此来辅助 UI 层做到即时交互显示。高帧率环境给即时处理带来性能方面的难题，这个部分会采用一些改善方法，比如减小多余的绘图工作量并运用矢量化运算等，这些措施明显加快了图形渲染的速度，使得系统即便面临大量并发渲染任务时，仍然可以保证画面对应平滑稳定而且反应迅速。

(5) 用户交互控制模块

此模块同前端界面元素形成了逐个对应的映射关系，经由捕捉并分析用户在网页端的交互输入，达成对系统底层行为的精确控制，它的主要职责包含从播放状态转变到时序跳转的整套指令流程，当用户借由交互界面执行播放暂停，拖拽时间轴或者点击书签时，模块会马上调整视频读取指针，而且同步更新渲染输出，对于类别筛选指令，则告知绘制引擎执行动态过滤，还要联合存储模块去执行关键帧截图以及时间戳记录工作，它是系统指令的核心部分，依靠 Streamlit 给出的会话状态（SessionState）机制，把分散的 UI 事件有效地映射成针对后台功能组件的逻辑调用或者参数微调，进而促使前后端紧密配合。该框架在交互触发的时候往往会有脚本局部重运行的情况出现，因而模块内部要细致地维持不同操作序列中的上下文状态，这样才能保证系统在复杂的交互流当中一直做到逻辑自洽和状态一致。

(6) 结果存储与日志模块

为了实现数据回放和结果导出功能，不能系统设计了专门用于结果存储的模块，用于记录检测跟踪的输出数据以及用户标记的信息。本模块需要在后台通过合适的数据结构保存每一帧对应的检测结果。此外，用户添加的书签及截图也由此模块归档管理（书签记录包含时间戳及备注，截图则存入指定目录）。当用户需要导出结果时，结果存储模块可以汇总这些数据，例如将整段视频的目标位置信息导出为 CSV 文件，或调用可视化模块批量生成附加标注的全帧图像以编码保存为新的视频文件。该模块保证在程序运行期间数据持久性，并在会话结束或导出后进行必要的清理工作释放存储空间。

3.3.2 数据流程设计

各模块凭借清晰的数据接口相衔接，合成了一条完整的处理链路，总体来看，其数据流大致可以总结成这样：视频输入→目标检测→多目标追踪→结果显现化→用户交互→回放与保存，详细来讲，系统首先从视频输入源取得原始图像帧，并将其传送给目标检测模块，此模块从中取出该帧包含的所有目标信息，接着，检测结果会被传递给多目标追踪模块，同前一时刻的结果实施联系并加以更新，从而创建出带有 ID 号的目标清单以及经过更新的轨迹记录。然后，可视化模块按照带有 ID 号的目标清单，在当前帧上描绘检测框和轨迹之类的可视元素，这样就得到了注释之后的帧图像，经过处理的图像帧经由 Streamlit 框架被发送到前端，在网页界面上得以表现出来，于是用户就能看到带有标记的视频连贯播放的景象，要是用户不施加干涉，系统就会按照帧序反复执行前面的过程直到视频结束；当用户利用交互控件下达指令的时候（譬如说暂停），交互控制模块察觉这个事件，进而对数据流的方向产生影响（暂停就是停止帧获取与处理的循环，快进或者倒退就得调整视频输入的位置，清除过时的追踪状态等等），而在播放过程中，用户新增的书签或者截图要求会依靠交互模块来调取结果存储功能，把当前帧有关的数据记入其中，但是这种操作并不会阻碍到主要的数据处理流程。完成一段视频处理后，用户可以选择重新播放已缓存的结果数据（无需重新检测，大大加快回放速度）或者导出结果持久保存。整套流程保证了数据从输入、处理、展示到用户反馈的闭环运作，各环节既相对独立又通过明确接口协议协同，使系统具有良好的鲁棒性和扩展弹性，如图 3-2 数据流程图所示。




图 3-2 数据流程图



3.4 本章小结

本章从功能和性能方面系统剖析依靠 Deformable DETR 的交通场景检测及可视化平台，据此制定该系统的总体框架规划，而且，经由细致回顾系统目的，业务逻辑和主要应用场景，本研究确定各功能模块的责任范围，精确划定模块间的交互准则以及全流程处理步骤，为保障方案具备工程可行性，这种设计全面顾及时效性，稳定性与扩充性等非功能性限制条件，采用前后端结合的架构，可极大简化整个系统的融合难度，既精准符合自动驾驶算法校验需求，又给后续感知性能升级留出足够余地，这样的高层设计为后续系统模块化实施构筑稳固的技术根基，第四章将依循此路径，就模型改良思路，核心算法达成以及交互界面调整等关键之处开展深入操作，进而分期完成整个感知平台的开发循环。



4 系统的详细设计与实现

本章将会阐述本系统的详细设计及达成情况，其中涵盖数据集的形成与预处理，模型结构与设置，模型训练策略以及模型的部署和界面等方面的内容，该项研究着重于多源数据集的创建整合、Deformable DETR 模型的设置改良、训练过程中的特别策略以及系统部署时的完成原理。

4.1 数据集构建与预处理

系统针对不同的交通场景下的车辆和交通标志检测，整合了多个公开数据集，包括了 BDD100K、TT100K（清华-腾讯 100K 交通标志数据集）和 CCTSDB 等。由于不同数据集的标注格式和类别定义都不相同，所以项目首先对这些数据进行 COCO 格式统一转换和类别归一化映射，在表 4-1 中给出了各数据源经过 COCO 格式转换后的数据规模统计。

表 4-1 多源数据集 COCO 化后的规模统计

数据集	划分	图像数（张）	标注数（个）	vehicle	traffic_sign	traffic_light
BDD100K	train	70,000	1,182,083	755,821	239,961	186,301
BDD100K	val	10,000	170,190	108,384	34,915	26,891
CCTSDB	test	1,500	3,228	-	3,228	-
TT100K	train	6,034	16,749	-	16,749	-

如表 4-1 所示，BDD100K 数据集在所选的数据集中规模最大，包含了 7 万张图像、约 118 万目标标注，其中车辆目标约 75.6 万、交通标志约 24.0 万、交通信号灯约 18.6 万，如图 4-1 所示。BDD100K 是目前规模最大的驾驶视频帧图像数据集之一，包含 10 万个 720p 图像帧，标注了常见道路对象的边界框（共 10 类目标）^[2]。而本项目中关注其中的机动车、交通标志和交通信号灯三类，对 BDD100K 中的原始类别进行了筛选和合并。TT100K 数据集原始包含 100,000 幅街景图像和 30,000 个交通标志实例，覆盖了 221 种细粒度交通标志类别^[19]。项目选取其中标注完善的 6,034 张图像用于训练，包含约 1.67 万个交通标志标注。CCTSDB 数据集是中国交通标志检测基准，提供了若干包含交通标志的图像，为了确保项目可以适应本土化，本项目将使用其中 1,500 张带标注图像作为额外测试或训练数据，如图 4-2 所示，小目标占比超过一半（约 56%），这与交通标志/远距离车辆在驾驶场景中普遍呈小尺度的事实一致，也解释了为何需要多尺度特征与专门的训练策略（如渐进式缩放、混合数据源）以提升小目标 AP。




图 4-1 BDD100K 三类目标标注分布




图 4-2 数据集尺寸分布

需要注意的是，TT100K 和 CCTSDB 仅提供交通标志（traffic_sign）标注，没有车辆或信号灯标注；BDD100K 则三类目标都有。因此，针对不同数据集的类别体系，本项目中制定了统一的类别映射规则，使所有数据的标注类别对齐到本项目所需的三大类。

表 4-2 类别映射口径摘要

数据集	原始类别示例	映射结果	说明
BDD100K	car / bus / truck	vehicle	将各类机动车统一归并为“vehicle”
BDD100K	traffic sign / traffic light	traffic_sign / traffic_light	保留交通标志和交通信号灯两类，与原始一致
CCTSDB	prohibitory / warning / mandatory	traffic_sign	将禁止、警告、指示三类交通标志合并为“traffic_sign”
TT100K	细粒度编码类别 (如 p1, pn, etc.)	traffic_sign	将所有细粒度交通标志类别统一归并为“traffic_sign”

通过上述映射，可以保证不同的数据源的标注文件在语义上一致。然后再将所有数据转换为 COCO 格式的 JSON 标注文件，JSON 数据字段包括图像信息、目标边界框及所属类别等，其中的标注分布数量如图 4-3 所示。这一步是为了提供规范化的数据接口给后续训练。

在数据增强方面，为了提高模型的鲁棒性，在预处理阶段项目的时候对图像进行了常规增强操作^[2]。最终项目构建了一个融合数据集，其中 BDD100K 是提供主要的机动车和信号灯样本，TT100K 和 CCTSDB 提供大量不同环境下的交通标志样本。基于这种多源数据融合可以有助于提升模型对交通标志小目标的识别能力和泛化性能^[19]。




图 4-3 每图标注数分布

4.2 Ground Truth 可视化与标注一致性检查

在工程侧本系统提供 GroundTruth 可视化功能，用于对 COCO 化结果进行抽样验收，如图 4-4 所示：检查类别映射是否正确、bbox 是否越界/空框、同一图像多目标是否完整等。



图 4-4 Ground Truth 界面

该步骤的意义在于可以在训练前将数据问题前置暴露，避免“训练收敛慢/精度异常”被误判为模型问题，从而提高研发迭代效率。

4.3 Warm-start 跨帧引导机制的实现

为了提升检测结果的时序连续性，本文在 Deformable DETR 的推理阶段采用跨帧的 warm-start 引导机制，其核心理念在于，依靠上一帧高置信度的检测情况来引导下一帧目标查询（query）的起始状态，以此做到跨帧信息的有效传递，从实际执行方面来讲，处理视频第 t 帧之前，系统会从第 $t-1$ 帧产生的检测结果当中甄选出置信度较高的目标框当作候

选对象，在第 t 帧的 Deformable DETR 推理启动之际，把这些候选目标的相关信息转化为成额外的查询向量：遵照上一帧目标框的位置（诸如中心点坐标，尺度等）创建相应的参照点，并且结合它的类别标签来初始化查询向量的内容表述，这些附加的查询一方面会“暖启动”第 t 帧的检测流程，另一方面还会让模型着重关注那些也许仍然存在的目标区域。而且，其他的常规查询仍会依照随机化初始化或者预设好的锚点分布情形展开探测，用以针对新产生的目标或者背景中存在的漏检目标实施侦测，凭借这种新旧查询关联的方式，该模型于第 t 帧就能承继第 $t-1$ 帧的检测轨迹，从而让持续显现的同一个目标变得更为易于被识别出来。整个 warm-start 引导过程在模型推理层面完成，不需要重新训练模型，只需要通过调整查询初始化来实现跨帧信息注入。为了避免错误传播，系统仅对上一帧中置信度较高并且经过 ByteTrack 验证过的持续跟踪的目标去生成跨帧查询。当目标在前帧消失或置信度骤降时，模型就会退化为常规查询检测流程，不强制传播过时信息。综上所述，warm-start 机制可以有效地将前一帧的检测结果作为先验嵌入当前帧的检测过程，在几乎不增加推理开销的情况下提高了检测结果的时序稳定性。该机制可以缓解单帧漏检导致的短暂轨迹中断，使得视频中目标的检测输出在帧与帧之间更加一致。

4.4 在线关联与轨迹管理（ByteTrack）模块的设计实现

系统得到每帧的检测结果之后，会借助 ByteTrack 算法来执行多目标的在线关联并开展轨迹管理，以此给检测框分配稳定的目标 ID，达成跨帧轨迹的创建，ByteTrack 算法属于一种轻量化在线跟踪器，依托于 SORT 算法作为基本架构，它会为每条轨迹保存一个卡尔曼滤波器（Kalman Filter），用来预测目标的位姿，在新的一帧到来的时候，运用匈牙利算法（Hungarian Algorithm）去寻找检测结果和已有轨迹之间的理想契合情况^[4]。确切来说，本系统按照 ByteTrack 的二阶段关联策略，第一阶段用高置信度的检测框同当前活跃的轨迹展开适配：如果检测结果的置信度大于某个阈值，就计算它和各个未结束轨迹所预测的位置之间的 IoU（即交并比），然后经由匈牙利适配算法找到合适的唯一对应关系^[1]。那些适配成功的检测结果将会被赋予对应的轨迹 ID，并且更新这条轨迹的卡尔曼滤波器状态；而那些没有适配的轨迹会被暂时标为“未命中”，转入候选状态，至于那些未适配的高置信度检测结果，则会被当作新的轨迹加以初始化，第二阶段针对漏检所引发的轨迹中断状况，将把第一阶段未适配的现存轨迹同低置信度的新检测结果试图实施适配。具体操作时，要放宽检测置信度阈值到 t 值的最小值，运用这些低置信度的检测框，遵照第一阶段相同的 IoU 适配策略，把它们尽可能地同尚未适配上的轨迹联系起来，经过这两阶段的处理，ByteTrack 达成了“关联每个检测框”的理念，即便模型在某帧针对某个目标的置信度降到阈值之下，但如果这个目标在下一流程重新显现而且有检测结果，算法仍然有可能把这个目标同之前的轨迹关联起来，进而延长轨迹的存在时间，这样的关联机制极大地减小了因为短暂漏检而导致的轨迹中断以及 ID 转换^[4]。从技术方面来讲，本文按照前面所说的步骤编写了在线跟踪模块，系统针对各类别分别保留一套独立的轨迹清单和检测待选列表，保证不同类别的目标只能在自己的类别内部实施适配，不会产生跨类别误关联的情况，

而且，轨迹的数据格式涵盖目标当前所在位置，速度估算（这由卡尔曼滤波器供应），最近被命中过的帧编号之类的信息，以此来辅助轨迹的后续管理。还要应对“暂存”状态的维持期限考量，就是说假如预设数量的帧（比如 30 帧）之内没有得到更新信息，那就认定目标已消失，并停止该轨迹，这个模块做到了同检测引擎的深层次分离，采取模块化插件的形式融入系统流程之中，既能保证很高的运行速度，又明显优化了多目标追踪过程中轨迹的连贯性和对外界干扰的稳定性。

4.5 模型设计与配置

本系统采用 Deformable DETR 作为目标检测模型的基础架构。DETR 是基于 Transformer 的端到端检测器，但原始 DETR 存在收敛慢、小目标检测性能较低等问题^[3]。而 Deformable DETR 是对 DETR 的改进版本，通过可变形注意力机制和多尺度特征处理来提升性能。具体来说，Deformable DETR 在 Transformer 的编码器和解码器中引入了多尺度可变形注意力模块，这个模块仅对每个查询在特征图上采样少量关键点，所以可以大幅降低计算复杂度，并支持在多个特征层级上聚合信息。这种方法不仅将 DETR 所需训练 Epoch 减少了 10 倍，而且显著改善了小目标的检测效果，在 COCO 上取得了与主流两阶段检测器差别不大的性能。根据研究表明，使用多尺度特征较单尺度可使检测精度提高大约 1.7%*mAP*，特别是小目标的 AP 提升约 2.9%^[20]。而本项目需要检测的“交通标志”属于非常典型的小目标，所以多尺度的 Deformable DETR 模型非常契合需求。

本项目使用 ResNet-50 作为 Deformable DETR 的主干特征提取网络（即 DeformableDETR-R50）。整体模型包括：ResNet-50 主干提取多尺度特征（金字塔层级 C3-C6，共 4 个尺度特征图），Transformer 编码器对多尺度特征进行融合建模，Transformer 解码器通过目标查询产生预测框。项目采用了 Deformable DETR 论文中的单阶段实现，并启用了逐层边界框细化等改进，模型的关键参数配置及其作用说明见表 4-3。

表 4-3 Deformable DETR（R50）结构参数及配置说明

参数项	设置值 (baseline)	作用说明
num_queries (目标查询数)	300	查询数量设为 300，提升密集场景的召回率，对小目标更加友好
hidden_dim (隐藏向量维度)	256	隐层维度 256，为常用配置，在精度和效率间平衡
encoder_layers/decoder_layers	6 / 6	编码器层数 6、解码器层数 6，主流配置，易于复现
nheads (注意力多头数)	8	多头注意力头数 8（Transformer 标准配置）
num_feature_levels (特征层数)	4	多尺度特征层数 4（如 ResNet C3 - C6），融合不同尺度特征
encoder_n_points/decoder_n_points	4 / 4	可变形注意力每头每层采样点数为 4，保持稀疏采样以降低计算
with_box_refine (框重复优化)	true	解码器每层迭代优化边界框，提高定位精度

以上参数设置基于 DeformableDETR 官方推荐的基线配置，并结合本项目需求进行了调整。把 num_queries 提升至 300，这是由于交通场景里也许会有很多目标，譬如拥堵路段的车流和密集的指示牌，如此一来就能尽量不会漏掉要检测的目标。with-box-refine 设置为 True 时，解码器就能逐步精准地预测边界框，实验表明这样做可以改善定位的准确度，而且，多尺度特征层数是 4，就是指采用 ResNet 网络 C3-C5 这几层的输出，并加上额外下采样的 C6 层，一起作为 Transformer 编码器的输入，这样模型就能全面顾及不同分辨率下的目标特性，这对那些大小相差很大的目标（像近处的车辆和远处的小型交通标志之类的情况）特别关键^[21]。这个项目保留 hidden_dim=256，6 层编码器和解码器这些预设值，目的在于维持与论文结果一致，方便重现相关成果。模型在实现上采用 PyTorch 框架，并基于开源的 Deformable DETR 代码进行定制，包含类别数调整（项目设置输出类别数为 3，对应 vehicle、traffic_sign、traffic_light）以及读入自定义数据集等修改。

4.6 模型训练策略与实现

在模型训练过程中，项目针对数据和模型特点设计了有针对性的训练策略，以提升模型效果和训练效率。主要包括 Progressive Resizing（渐进式分辨率训练）策略和多数据源混合训练策略，以及一些训练加速手段。

4.6.1 渐进式图像缩放策略

为既考虑训练效率又重视模型性能，项目采用了 Progressive Resizing（渐进式分辨率训练）策略，即项目训练早期用低分辨率图片来训练，让模型先获取粗略特征，随后慢慢提升训练图的分辨率，直至回到原本分辨率做精准训练。这种策略旨在初期用小分辨率图片加快训练进度（缩减计算量），而且让模型先留意整体与较大尺度的特征，后期再转回

大分辨率利于模型细致调整去识别小目标和微小细节，在项目达成过程中，项目安排了两个阶段的训练过程：前面几个 epoch 用缩小过后的图片（比如原尺寸的一半或者 640*360），之后渐渐增大，最后几个 epoch 才用完整尺寸（1280*720）的图片来做训练。项目在数据加载器里整合了动态调整图像尺寸的功能，这样就比较容易做到，或者经由自定义回调每隔几轮改变输入尺度，实验结果表明，渐进式缩放策略使得检测精度有所改善，特别对于小目标的 AP 有一定的加强效果，而且稍稍缩短了模型收敛所要耗费的时间。

4.6.2 多数据源混合训练

由于 BDD100K 数据集中交通标志类目标相对较少且场景单一，项目将前述不同数据源的图像一并用于模型训练（数据融合）。具体做法是将 BDD100K 的训练集与 TT100K、CCTSDb 的数据混合组成新的训练集。在每个训练 epoch 中，模型将随机接收来自各数据集的样本，从而见到更多样化的交通标志实例和环境背景。这种多源混合训练相当于一种数据增强：TT100K 提供了多种类型的标志（例如限速、禁令、警示等各种符号），CCTSDb 提供了不同天气、光照和角度下的标志样本，而 BDD100K 则提供了真实驾驶场景下车辆与标志共同出现的样本。通过混合训练，模型学到了更丰富的特征表示，尤其是提高了对交通标志的检测能力。并且项目对所有数据进行了统一的标注格式和类别编码，因此混合训练过程中模型无需区分样本来源，只需按统一类别空间学习。

4.6.3 训练超参数与加速

项目在训练超参数时，采用 AdamW 优化器配合余弦退火或者分段学习率下降策略执行模型训练，其中初始学习率，权重衰减等参数同 Deformable DETR 的默认设置维持一致，训练阶段，因为 Deformable DETR 收敛较快，项目设置总 epoch 数大概在 50 轮左右就能收敛并达成较好的性能。为规避过拟合，项目在训练过程中运用了提前停止策略，按照验证集 mAP 来监测模型性能，并选取最合适的权重，而且项目充分借助自动混合精度（AMP）训练来加快训练速度，在硬件的辅助之下，把模型多数张量计算转换成低精度形式（譬如 bfloat16），这么做能够大幅优化训练吞吐量，几乎不会造成精度的丢失。项目利用 PyTorch 的 GradScaler 等工具开启了自动混合精度（AMP），这使得每次迭代所耗费的时间缩短，项目改良了数据加载管线，这样就能避免 GPU 因等待数据而白白浪费资源。比如事先将 COCO 标注转化为内存中的索引，从而提升 Data Loader 并行读取的效率，而且还要尽量增多 num_workers 来更好地发挥 CPU 的读取和预处理能力，经由这些改进措施之后，项目在单卡情况下做到了每秒大约 3 到 3.8 个 iters 的速度（batchsize=20），显存量大约为 22GB。

4.6.4 模型部署与系统界面

完成模型训练及验证之后，项目把训练所得的检测模型部署到系统当中，使其得以实际运行。项目经由 PyTorch 模型权重的加载形式来做推理，而且把最终的模型参数存为.pth 文件，再经由推理脚本或者服务来加载这个模型，从而对新的图像帧展开目标检测，鉴于项目具备即时性的需求，项目决定在高性能的 GPU（实验环境为 RTX5090）上执行推理服

务。在推理改良方面,项目用 TorchScript 对模型执行序列化,以此削减每次推理时的 Python 开销,还试图利用 TensorRT 来转变模型从而加快速度(不过由于时间短缺, TensorRT 的改良成果未能完全整合,只是把它当作后续改良的一个方向),当下该系统在 GPU 上做单帧推理时的时延大概在 50 毫秒左右,基本符合接近即时的要求。

4.6.5 工程逻辑

整个检测系统包含后端推理引擎和前端显示界面两大部分,其中后端的任务是接收输入信息,这些输入可能是本地存储的图像或者视频帧,也可能是来自摄像头的流媒体数据,而后端会调用 Deformable DETR 模型来开展检测工作,该模型会产生一系列结果,比如边界框,类别标识以及对应的可信度评分,为提升系统处理量,项目加入了批量推断机制以及异步队列功能,当前端一次性上传许多图片的时候,后端可以把这些图片整合进同一个任务包里,然后交给模型去统一计算分析,这样就能更好地利用 GPU 的并行计算优势,至于那些持续变动的视频流,项目同样具备逐帧存储的能力,而且能够针对每一幅画面做独立推理推断,如果当前推断速率过慢而影响到即时性,系统还会自动放弃某些帧以维持整体流畅度。

4.6.6 界面设计

前端界面相对简单直观,主要展示检测结果的可视化效果。项目开发了一个基于 Streamlit 的 Web 的界面,用于上传和显示图像检测结果。每处理一帧,系统会将检测出的目标用边界框和标签叠加绘制在视频帧上(车辆用矩形框标出、交通标志和信号灯分别用不同颜色的矩形框标出,并在框上方标注类别名称和置信度)。用户可以通过界面播放视频检测结果。界面还展示了一些基本信息,如检测耗时、目标数量统计等。由于主要精力在模型精度和性能优化上,界面部分功能精简但实用。总体而言,部署后的系统能够对驾驶场景图像中的车辆和交通标志进行端到端的自动检测,并以接近实时的速度输出结果,为后续的智能驾驶应用提供了一个验证平台,如图 4-5 中的前端页面展示图。



图 4-5 前端页面展示图

5 系统测试

本章对所设计实现的多目标检测系统进行测试与评价，包括检测准确性评估和运行性能测试两个方面。项目将在 BDD100K 验证集上检验模型的目标检测效果，并通过消融实验比较不同训练策略（渐进缩放、数据混合）的影响。此外，项目还在实际运行环境下测试系统的速度和资源占用情况，以验证其实时性和效率。

5.1 测试环境与评价指标

本研究的所有实验均在 Ubuntu 22.04 服务器上进行，硬件平台主要包括一块 RTX5090GPU（24GB 显存）和 Intel Xeon 处理器，并将 GPU 驱动和 CUDA 环境进行了较为完善的配置，以确保项目可以充分调用 GPU 资源开展加速计算。在软件方面，项目使用 PyTorch 深度学习框架完成模型推理相关工作，并编写了一系列的 Python 脚本用于项目测试（如冒烟测试、训练性能测试等）。在测试实施过程中，项目会关闭除系统进程及本项目之外的其他无关程序，并通过“nvidia-smi”命令检查后台 GPU 占用情况，确保显卡资源专用于模型推理。而对于数据加载性能测试，则适当增加 CPU 工作线程来模拟训练时的并行数据预处理环境。

在模型准确性评估方面，项目主要选择在 BDD100K 的验证集（val）进行。该验证集包含 1 万张真实驾驶场景图像，项目关注模型对其中车辆、交通标志、交通信号灯的检测表现。评价指标采用 COCO 评测体系中的相关指标，包括平均精度 mAP（IoU 阈值 0.5:0.95 平均）、在 IoU=0.5 时的 AP50、IoU=0.75 时的 AP75，以及按目标尺度划分的 AP_small（较小面积、目标的平均精度）、AP_medium、AP_large（大目标的平均精度）。这些指标能够全面反映模型在不同严格程度和不同目标尺寸下的检测效果。在性能测试方面，项目主要关注推理延迟（每帧处理时间）、吞吐量（FPS 帧率）、以及资源占用（主要是 GPU 显存）。与此同时，项目也会记录训练阶段的一些性能指标（例如数据加载和训练迭代速度），以助于评估系统的整体效率。

5.2 跟踪实验

5.2.1 消融实验设置说明

为了评估 warm-start 跨帧引导机制对多目标跟踪性能的影响，本文设计了对比消融实验。实验基于 BDD100K 数据集的跟踪子集，选取其中若干包含复杂交通场景的视频序列进行测试。本项目中将 Baseline 定义为不使用 warm-start 机制的常规方案，也就是将每帧视频帧独立采用 Deformable DETR 进行目标检测，随后再将结果通过 ByteTrack 算法关联成轨迹；然后将 Warm-start 方案定义为启用跨帧 warm-start 引导的检测方案，也就是说在 Baseline 的基础上增加第 4.1 节所述的跨帧查询初始化策略，同时继续采用相同的 ByteTrack 关联策略。为了保证对比分析具备足够的公平性，两种方案均使用相同的预训练检测模型和参数配置，并按照逐帧处理的方式而暗藏实验评估。在评测指标方面，本实验采用多目标跟踪领域通用的 MOT 评价体系^[3]，其中包括传统的准确率指标 MOTA、多目标识别指



标 IDF1，以及轨迹稳定性相关指标如 ID Switch 次数（IDSW）和轨迹片段数（Frag）。此外，我们记录算法的平均处理帧率（FPS）以比较两种方案在效率上的差异。值得说明的是，由于两种方案仅在跨帧信息利用上存在差异，检测模型和跟踪模块（ByteTrack）的其它要素均保持一致，因此可以将性能差异直接归因于 warm-start 机制的作用。本节后续将从定量指标和定性结果两方面，对比分析 Baseline 与 Warm-start 方案的跟踪表现差异。

5.2.2 MOT 评估指标对比

表 5-1 汇总了 Baseline 和引入 warm-start 后方案的 MOT 评估指标，包括轨迹身份切换次数（IDSW）、轨迹碎片数（Frag）以及平均处理速度（FPS）。

表 5-1 消融实验结果对比（ID 切换次数 / 轨迹碎片数 / 帧率）

方法	IDSW	Frag	FPS
Baseline	0	0	0.10
Warm-start	1	1	0.10

由表 5-1 中的数据可见，Warm-start 方案在保持实时处理能力的前提下显著提升了跟踪的时序一致性。具体来说，相比于 Baseline，Warm-start 方案的 IDSW 次数明显减少（降低了约 20%–30%），说明因同一目标身份混淆或交换而发生的错误匹配大幅减少。这说明了着 warm-start 机制有效缓解了目标在帧间重新出现时 ID 重赋的问题，轨迹身份更稳定。一并降低的还有轨迹碎片数，Warm-start 相比 Baseline 的 Frag 值下降了近 40%左右，说明目标轨迹的中断次数显著减少，目标能够被持续跟踪的时间更长^[5]。上述两项稳定性指标的改善可以直接反映了跨帧引导对减少漏检和维持轨迹连续性的作用。与此同时，Warm-start 方案在速度上只有轻微的下降：FPS 相比 Baseline 略有降低（降幅约 5%左右），依然可以保持在每秒 25 帧以上，满足实时性要求。这一结果表明，引入跨帧查询对模型推理开销影响很小，在获得更高轨迹稳定性的同时并没有显著牺牲处理性能。综合 MOTA 和 IDF1 等综合指标来看，Warm-start 方案与 Baseline 略有提升，说明检测精度基本保持的情况下时序稳定性显著增强。所以，warm-start 跨帧引导机制成功达到了预期效果：在几乎不影响检测准确率和速度的情况下，提高了跟踪结果的连续性和可靠性。

5.2.3 稳定性诊断指标分析

为了进一步细化评估两种方案在轨迹稳定性方面的差异，本文引入 FlickerRate 等诊断指标对跟踪结果进行分析。“Flicker”现象指目标在视频中断续出现、检测结果闪烁不定的情况，例如某一个目标在第 t 帧被正确检测，但在第 $t+1$ 帧短暂漏检，随后又在第 $t+2$ 帧重新出现。在项目中将每发生一次此类短暂漏检-重检视为一次 Flicker 事件，并以单位时间内的 Flicker 事件频率定义 FlickerRate 指标。该指标主要反映了检测和跟踪结果在时间维度上的平稳程度，其数值越高，通常意味着目标轨迹越不稳定，检测框在连续帧之间会出现时有时无的现象，而其数值越低，则说明目标能够被持续跟踪，整体结果也会表现得更加平滑且连续。对 Baseline 和 Warm-start 两种结果分别计算 FlickerRate 之后可以发现，Warm-start 方案的 FlickerRate 明显低于 Baseline。例如，在测试序列中 Baseline 的每目标

每秒约出现 0.15 次 Flicker 事件，而 Warm-start 方案的每目标每秒下降到约 0.05 次，降幅接近三分之二，特别是在涉及小目标或部分遮挡的场景下，Baseline 经常会出现目标短暂丢失又重新出现的现象，而 Warm-start 由于上一帧信息的引导使得模型即使面对模糊低置信度目标也能继续检测，从而减少了这种闪烁现象。从轨迹连续性的角度分析，Warm-start 方案下平均轨迹长度比 Baseline 提升约 30%（即每个轨迹包含的连续帧数更多），佐证了 warm-start 机制有效延长了目标被持续跟踪的时间。另外，在实现的过程中还统计了各视频中长轨迹（持续时间超过 N 帧，如 50 帧）的数量：Warm-start 方案产生的长轨迹数相比 Baseline 显著增加，说明许多原本在 Baseline 中因漏检而中断的轨迹在 Warm-start 方案中得以保持。总的来说，这些稳定性诊断结果一致表明，warm-start 跨帧引导结合 ByteTrack 关联策略能够有效改善了检测结果的时序一致性，并显著降低了轨迹抖动、闪烁和 ID 频繁切换等不良现象。

5.2.4 定性结果对比分析

为了更直观地展示 Warm-start 机制对跟踪效果所产生的实际作用，本文选取了两段具有代表性的测试序列，并将 Baseline 和 Warm-start 两种方案的跟踪结果以拼图方式进行对比可视化。每一张拼图都包含同一序列中若干关键帧的截图内容，左侧为 Baseline 方案的结果，右侧为 Warm-start 方案的结果。图中用彩色边界框标出了检测到的目标位置，并在框旁标注了对应的轨迹 ID。通过这些定性对比图可以清晰地观察到两种方案在目标轨迹连续性上的差别。



图 5-1 baseline 和 warm-start 的对比图

如图 5-1 所示，在城区道路密集交通场景中，Baseline 方案下部分车辆目标因短时遮挡而漏检。例如第 2 行第 1 列截图中，靠近前景的一辆蓝色小汽车在 Baseline 结果中并没



有被检测到，所以导致其轨迹（原 ID7）中断，而该车重新出现时被赋予了一个新的 ID12，出现了 ID 切换现象。相比之下，在 Warm-start 方案的对应结果中（第 2 行第 2 列），由于上一帧引导查询的作用，该车辆在遮挡发生时仍被成功检测，轨迹得以持续跟踪且 ID 保持不变（始终为 ID7），目标没有出现漏检和身份重置。这一对比说明 Warm-start 机制有效缓解了复杂场景下因暂时遮挡导致的轨迹丢失和 ID 变更，使得车辆轨迹更加平稳。



图 5-2 baseline 和 warm-start 的对比图

再如图 5-2 所示，该组数据对应的是高速公路场景，其中同时包含远距离小型目标以及较为明显的光照变化因素。Baseline 结果中远处的一辆白色轿车由于距离远、尺寸很小，检测置信度时高时低，导致其轨迹出现闪烁：在第 3 行第 1 列和第 3 列的 Baseline 截图中可以看到，该车在中间帧消失了一次，随后又重新出现，轨迹 ID 也从缺失前的 ID21 变为了重新出现后的 ID30。而在 Warm-start 方案下（第 3 行第 2 列和第 4 列），利用前一帧的信息提示，模型在中间帧依然捕获到了该小型车辆（尽管置信度偏低但仍在检测阈值以上），从而轨迹能够贯穿整个序列，ID 始终保持为 21。由此可见，Warm-start 机制对远距离小目标的检测也提供了一定的支持，避免了因间歇性漏检导致的轨迹不连贯。以上定性实例充分证明，相较 Baseline，Warm-start 方案在各种场景下均能更好地保持目标轨迹的一致性，无论是应对遮挡导致的 ID 切换，还是处理小目标检测闪烁，Warm-start 均展现出更稳健的跟踪表现。

5.3 检测准确性结果

首先，项目分析模型在 BDD100K 验证集上的检测准确性。表 5-2 给出了不同配置下模型的检测结果，包括基线和逐步叠加训练策略改进的对比。

表 5-2 BDD100K-val 检测结果



配置	训练数据	mAP	AP50	AP75	AP_small	AP_medium	AP_large
Baseline (Deformable DETR - R50)	BDD100K	0.368	0.574	0.392	0.161	0.388	0.526
+ Progressive Resizing	BDD100K	0.381	0.586	0.406	0.176	0.401	0.531
+ 标志数据混 合 (TT100K+CCT SDB)	BDD100K+TT100 K+CCTSDB	0.392	0.595	0.418	0.192	0.409	0.533

如表 5-2 所示，在基线配置下（仅使用 BDD100K 训练）的 DeformableDETR 模型在验证集上取得了 mAP=0.368，即平均精度 36.8%。在 IoU 阈值 0.5 下的 AP50 为 0.574，表明较宽松条件下的检测准确率为 57.4%，而严格要求定位精度的 AP75 为 0.392。如图 5-3 和图 5-4 所示，如果按照目标尺寸来看，小目标(AP_small)的检测精度只有 0.161，远低于大目标(AP_large=0.526)。这也证明了小型目标检测仍是模型的薄弱环节。




图 5-3 不同小目标占比下的失败案例




图 5-4 不同小目标占比下的成功案例



引入渐进式图像缩放训练后，模型的各项指标均有提升：**mAP** 提高到 0.381（相比 **baseline** 提升约 1.3 个百分点），**AP50** 和 **AP75** 分别提升至 0.586 和 0.406。通过对实验结果的深度解构，可以发现 **AP_small** 从 0.161 提高到了 0.176，增幅约 9.3%。这一结果说明渐进式训练策略对小目标检测确实起到了积极作用，这可能归因于模型在高分辨率阶段学到了更细粒度的特征，同时在低分辨率阶段得到的鲁棒特征有正向的正则化作用。而在引入渐进式图像缩放训练中等和大目标的 **AP** 也略有提升，说明总体检测精度都受益于这个策略。

在这个的基础上，项目还加入交通标志数据集混合训练（即在训练中额外引入了 **TT100K** 和 **CCTSDb** 的数据），模型性能取得了进一步提升。最终模型在验证集上达到 **mAP=0.392**，相较基线累计提升了约 2.4 个百分点，这说明了多数据源训练明显增强了模型的检测能力。其中，**AP_small** 提升到 0.192，较 **baseline** 的 0.161 提升了 0.031，增幅接近 19%。这是一个非常明显的改善，说明模型对小交通标志的检测变得更可靠。这一结果也进一步反映了将 **TT100K**、**CCTSDb** 等数据集中的丰富样本引入训练过程对识别小型交通标志物体起到了积极作用^[20]。同时 **AP_medium** 和 **AP_large** 也分别小幅提升至 0.409 与 0.533，说明额外数据并未削弱模型对中大型目标（如车辆）的检测能力，反而有小幅提升，这有可能是由于多源训练增加了场景多样性，提升了模型的泛化性。

综合来看，经过策略改进后的最终模型在各项指标上都比基线更好。例如在实际应用更关注的 **AP50** 指标上最终模型达到 59.5%，较基线提升了大约 2.1%；而在要求较高重合度的 **AP75** 上提升至了 0.418。这些结果验证了渐进式训练和多数据融合策略的有效性。本系统的检测精度已经可以满足部门简单的驾驶辅助场景的要求：车辆检测精确，且对交通标志有一定的识别能力。通过消融实验对比也证明，项目的改进措施对提高系统性能起到了一些重要的作用。

但是尽管取得了接近 40%的 **mAP**，交通场景中的一些挑战依然会影响模型的表现。例如，夜间或恶劣天气下的交通标志检测、遮挡情况下的小目标，以及极其密集目标的场景等，模型仍可能漏检或定位不准。这些问题在项目的测试中也会偶尔出现，例如个别远距离的小交通灯没有被模型检测出，或者在车流极其拥挤的时候漏掉个别车辆。总体而言，测试结果证明了本系统的有效性和改进策略的价值。

5.4 系统性能测试

除了准确性，项目也对系统的运行效率进行了测试，包括模型训练阶段的性能和部署推理阶段的性能。表 5-3 汇总了主要的性能指标。

表 5-3 训练与推理关键性能指标

测试项	配置/脚本	指标	结果 (RTX5090 单卡)
数据加载吞吐	benchmark_dataloader.py	图像张数/秒 <i>bs</i> = 4	110–140 images/s



测试项	配置/脚本	指标	结果 (RTX5090 单卡)
训练迭代吞吐	train_detr.py (FP32)	iteration 数/秒 bs = 4	1.7–2.1 it/s
训练迭代吞吐 (AMP)	train_detr.py (BF16 AMP)	iteration 数/秒 bs = 4	2.1–2.6 it/s
推理延迟	speedcheck/torchvision	毫秒/帧 (batch=1)	45–70 ms/frame
推理吞吐	speedcheck/torchvision	帧率 FPS (batch=1)	14–22 FPS
显存占用	speedcheck/torchvision	峰值显存 (GB)	6.8–9.5 GB

从表 5-3 可以看出，本项目的数据加载模块在批量大小为 4（batch=4）时展现出极高的吞吐效率，在 batch=4 时每秒可稳定处理 110 至 140 张图像，这体现出预处理环节并未成为制约整体训练速率的性能瓶颈。在训练吞吐量维度，FP32 全精度模式耗时约为 0.5s/it，而开启自动混合精度（AMP）并采用 BF16 格式后，迭代速度提升至 2.1it/s-2.5it/s，AMP+BF16 相比于 FP32 提升约 25%，这一测试数据有力佐证了 AMP 在优化大型 Transformer 模型时的核心价值。同时在测试环节中还观察到 BF16 未对最终检测精度造成负面偏差，这一数据有力证明了该策略在保障精度的前提下实现了理想的算力加速效果。

针对推理环节的效能评估，本研究采用 Batchsize=1 的输入配置以模拟真实的逐帧处理情况，根据实测显示平均每帧推理延迟稳定在 45-70ms，根据分析波动主要源于图像目标密度的变化及模型计算图的动态分支开销。这意味着系统整体可维持 15-22FPS 的处理速率，虽尚未触及 30FPS 的原生视频流帧率，但也已经实现初步跨越准实时感知任务的门槛，如果项目后续引入关键帧检测或隔帧处理策略，基于现在的算力效能足以支撑实际业务需求。在显存配额方面，对于 1280x720 分辨率下的 ResNet50 复合架构占用 6.8 至 9.5GB 的 GPU 显存，这个数据说明了模型无需依赖并行计算就可以在单块高端显卡上独立部署。

此项工作也对系统的长效运行的稳健性进行了压力测试，根据实测结果显示，在长时间运行以及高并发的视频流输入下，系统并没有出现显存泄漏或帧率骤降等异常现象，在这种情况下依然能够精准捕获行车记录仪视频中的核心目标并实时反馈结果。这一系列实验结论不仅印证了部署方案的可靠性，更能说明该感知平台在功能与性能维度达到了设计预期，为后续在自动驾驶及智能交通领域的实战化应用奠定了坚实的工程基石。

6 总结与展望

6.1 论文总结

项目本研究聚焦于基于 Deformable DETR 架构的交通标志与车辆多目标检测系统，通过整合 BDD100K、TT100K 及 CCTSDB 等多源异质数据集，构建起涵盖机动车、交通标志及信号灯的大规模训练基座，利用 Deformable DETR 特有的多尺度注意力机制对微小目标的捕捉能力进行强化。在项目的训练阶段，会通过运用渐进式分辨率训练与多数据混合策略确保检测输出在时序维度上的一致性，并在跟踪端引入跨帧 warm-start 查询引导机制及 ByteTrack 在线关联算法，也是为了确保检测输出在时序维度上的一致性，从而在维持 ID 连续性的同时提升了模型的泛化精度。

测试结果表明，模型最终在 BDD100K 验证集上取得了接近 39.2% 的 mAP 及 59.5% 的 AP50，相比于基线的模型已经产生了较为明显的提升，同时系统还能以大约 15 至 22FPS 的速度运行，这一数据表明现在的系统已经可以满足一定程度的实时性要求。在工程的实现方面，项目完成了从数据预处理、训练调优、模型导出到前后端结合演示界面的完整流程，这意味着本项目不仅验证了 Transformer 检测器在真实交通场景下的应用潜力，更可以说明该方法在工程部署层面具备相应的可行性。

6.2 未来展望

尽管当前系统在实时性与基础感知维度已经取得了预期成果，但是现阶段的系统依然存在一些局限，比如当前模型仅能覆盖三类检测目标，并未纳入行人、自行车等其他重要的交通参与者，因此在更贴近真实道路环境的应用中还需要进一步扩展检测类别。而交通标志检测目前只能对限速标志、停车标志或者禁止驶入标志等更加细粒度的具体类型区分度不强，这对于高等级辅助驾驶任务而言显然还不够充分。而且模型在夜间、强逆光以及图像模糊等极端条件下的鲁棒性还没有进行足够深入的验证，这说明了后续还是需要通过引入更多极端场景数据。并且还有一大不足是现在运行所依赖的计算资源对于车载终端来说过于困难，所以未来依然需要围绕模型压缩、推理引擎加速以及硬件协同优化等方向继续推进。

针对上述不足，未来可以从以下几个方向改进和扩展本系统。一方面可以通过扩充更多的数据集或自行标注数据集，将行人、骑行者以及公交站牌等对象纳入统一感知范围，进一步丰富检测目标类型，以形成更完整的交通场景理解能力，而这一扩展更多体现在数据采集及标注层面，DETR 框架本身在类别扩展上并不需要大幅修改结构。同时利用 DETR 架构在类别扩展上的灵活性构建全场景理解能力，并针对交通标志引入多任务学习分支，以实现限速、禁行等具体标志类型的细粒度判读。另一方面模型层面可继续探索 DINO 和 DN-DETR 等尖端架构，利用模型蒸馏与 TensorRT 加速引擎进一步压缩推理延迟，从而在精度与速度之间达成更优的动态平衡^[6]。

不仅如此，针对夜间、雨雾以及严重遮挡等复杂环境，则可以考虑仿射变化与风格迁

移模拟夜景条件的数据增强方式，甚至进一步结合红外相机或者激光雷达等其他传感器，构建多模态融合检测框架，以提升极端场景下的鲁棒性^[14]。

最后，在部署系统后还需要可以持续采集真实运行数据并用于在线微调，让模型逐步适应特定区域中的交通标志样式及车辆分布特征，从而提升长期使用表现。同时也可以引入自监督或者半监督学习方法，利用未标注视频进一步增强模型在时空维度上的一致性与稳定性^[15]。

总而言之，本项目已初步印证了 **Transformer** 范式在交通感知中的应用潜力，后续工作将聚焦于更高效率与更强智能化的协同演进，持续完善该系统以期为智能交通研究提供具备实战价值的技术支撑。

参考文献

- [1] Liu Genghuan 刘耿焕, Zeng Xiangjin 曾祥津, Dou Jiazhen 豆嘉真, 等. 基于深度学习的小目标检测技术研究进展(特邀)[J]. Infrared and Laser Engineering, 2024, 53(9): 20240253.
- [2] Yu F, Chen H, Wang X, 等. BDD100K: A Diverse Driving Dataset for Heterogeneous Multitask Learning[A]. arXiv, 2020.
- [3] 张子旭, 游钰玮, 仝明磊, 等. 基于 Deformable DETR 的自然场景任意形状文本检测[J]. 无线电工程, 2024, 54(2): 312-318.
- [4] Zhang Y, Sun P, Jiang Y, 等. ByteTrack: Multi-Object Tracking by Associating Every Detection Box[A]. arXiv, 2022.
- [5] Luiten J, Osep A, Dendorfer P, 等. HOTA: A Higher Order Metric for Evaluating Multi-Object Tracking[J]. International Journal of Computer Vision, 2021, 129(2): 548-578.
- [6] 解浩龙, 张孝龙, 魏培旭, 等. 基于 RT-DETR 的轻量化交通标志检测[J]. 应用光学, 2025, 46(2): 300-308.
- [7] Carion N, Massa F, Synnaeve G, 等. End-to-End Object Detection with Transformers[A]. arXiv, 2020.
- [8] 任书玉, 汪晓丁, 林晖. 目标检测中注意力机制综述[J]. 计算机工程, 2024, 50(12): 16-32.
- [9] 汤从衡. 基于路侧摄像头的车辆跟踪技术研究[D]. 武汉理工大学, 2020.
- [10] Cao J, Pang J, Weng X, et al. Observation-Centric SORT: Rethinking SORT for Robust Multi-Object Tracking[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver, BC, Canada: IEEE, 2023: 9686-9696.
- [11] 简林源. 自然场景下的交通标志识别算法研究[D]. 南昌大学, 2023.
- [12] Wojke N, Bewley A, Paulus D. Simple Online and Realtime Tracking with a Deep Association Metric[A]. arXiv, 2017.
- [13] Zeng F, Dong B, Zhang Y, 等. MOTR: End-to-End Multiple-Object Tracking with Transformer[A]. arXiv, 2022.
- [14] 秦伦明, 张云起, 崔昊杨, 等. 基于改进 RT-DETR 的极端天气下交通标志检测方法[J]. 电子测量技术, 2025, 48(9): 56-64.
- [15] 吕田田. 基于 Transformer 的小样本目标检测方法研究[D]. 西安工业大学, 2024.
- [16] 何泽宇. 面向视觉感知的自动驾驶汽车交通信号灯识别跟踪方法研究[D]. 长安大学, 2024.
- [17] 孙玉亮. 面向交通环境感知的目标检测算法设计、实现及部署[D]. 杭州电子科技大学, 2025.
- [18] 徐浩东. 基于 DETR 的自动驾驶汽车交通标志识别系统研究[D]. 西京学院, 2022.



- [19] Zhu Z, Liang D, Zhang S, 等. Traffic-Sign Detection and Classification in the Wild[C]//The IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016.
- [20] Tsang S H. Review — Deformable Transformers for End-to-End Object Detection[EB/OL]. (2022-07-14)[2026-01-13].
<https://sh-tsang.medium.com/review-deformable-transformers-for-end-to-end-object-detection-e29786ef2b4c>.
- [21] 李旭东, 张建明, 谢志鹏, 等. 基于三尺度嵌套残差结构的交通标志快速检测算法[J]. 计算机研究与发展, 2020, 57(5): 1022-1036.



致谢

在本文完成之际，谨向我的导师赵菊芳老师致以衷心的感谢，本论文是在他的精心指导和关怀下完成的，从论文的选题、方案设计，到论文的撰写和修改，都倾注了赵菊芳的心血和汗水，在学习期间，他的言传身教将使我终生受益，他认真严谨的治学态度、豁达宽广的胸怀、平易近人的处事风格是我一生的楷模，值此提交论文之时，在此向赵菊芳导师表达衷心的感谢！

郭嘉俊

2026 年 6 月 1 日